



Clasificación Cuántica sobre Hardware Real de IBM: Impacto del Ruido NISQ y Limitaciones de Muestreo

Edmil Jampier Saire Bustamante (174449)
Medaly Lozano Llacctahuaman (195040)
José Francisco Puma Potosino (164248)

Resumen. El presente estudio expande la evaluación de clasificadores cuánticos transicionando de entornos simulados hacia procesadores cuánticos reales (IBM Heron r2) de la etapa NISQ. Se evaluó el desempeño de Modelos Cuánticos Variacionales (VQC) optimizados y Máquinas de Vectores de Soporte Cuánticas (QSVC) frente a conjuntos de datos (Iris y MNIST) severamente restringidos a 15 muestras para ajustarse a las limitaciones computacionales de la plataforma IBM Quantum. Se evidenció empíricamente que la reducción muestral provoca un colapso en la capacidad de generalización del kernel cuántico (40 % de accuracy tanto en simulador como en hardware real), indicando que el cuello de botella predominante no es la decoherencia cuántica, sino la carencia de densidad topológica de los datos. Así mismo, métodos de mitigación de errores de lectura (TREX) resultaron inefectivos ante tan aguda varianza estadística.

Palabras clave: Hardware Cuántico, IBM Quantum, QML, Ruido NISQ, TREX, VQC, QSVC, Limitación Muestral.

1. Introducción

Durante la etapa computacional conocida como *Noisy Intermediate-Scale Quantum* (NISQ), los algoritmos híbridos y de aprendizaje automático cuántico (QML) emergen como candidatos principales para alcanzar ventaja cuántica. Sin embargo, su ejecución práctica está invariablemente condicionada por la decoherencia intrínseca y el ruido operacional de los procesadores actuales (Preskill, 2018).

En la primera fase de este proyecto, se exploró empíricamente el rendimiento de un Clasificador Cuántico Variacional (VQC) (Cerezo et al., 2021) y una Máquina de Vectores de Soporte Cuántica (QSVC) (Havlíček et al., 2019) utilizando un simulador ideal (*Statevector Simulator*). Los resultados demostraron que la QSVC poseía una ventaja matemática teórica respecto al VQC sub-entrenado, pero aún cedía frente a la eficiencia empírica de los clásicos algoritmos SVM-RBF y Redes Neuronales.

La presente **Segunda Parte** del estudio persigue un doble objetivo: en primer lugar, subsanar la convergencia defectuosa observada en el VQC mediante la dilatación del índice de optimización. En segundo y principal lugar, migrar la ejecución de la generación del Kernel

Cuántico desde un entorno libre de ruido hacia procesadores físicos de la plataforma IBM Quantum (familia *Heron r2*).

La pregunta de investigación rectora de esta fase experimenta no sólo busca medir el grado de *degradación* que sufre la métrica de exactitud (Accuracy) ante el ruido de hardware, sino también evaluar la verdadera aplicabilidad de técnicas algorítmicas diseñadas para la supresión de errores, específicamente la mitigación local de errores de medición de qubits (TREX), sobre conjuntos de datos fuertemente limitados por cuotas operacionales. El código fuente integral de este proyecto y los cuadernos de experimentación están documentados públicamente en el repositorio: https://github.com/milith0kun/Computacion_Cuantica.

2. Marco Teórico

Para contextualizar el impacto de las variaciones operativas durante la experimentación en QPU, se fundamentan teóricamente los métodos de evaluación del error de la plataforma.

2.1. Computación cuántica

2.1.1. Qubits y estados cuánticos

El qubit es la unidad fundamental de información cuántica (Nielsen and Chuang, 2010). A diferencia del bit clásico, puede existir en una superposición de los estados $|0\rangle$ y $|1\rangle$:

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle, \quad |\alpha|^2 + |\beta|^2 = 1, \quad (1)$$

donde $\alpha, \beta \in \mathbb{C}$ son amplitudes de probabilidad. Un sistema de n qubits vive en un espacio de Hilbert de dimensión 2^n , propiedad que constituye la base del potencial computacional cuántico.

2.1.2. Puertas cuánticas

Las puertas cuánticas son operaciones unitarias que transforman el estado de los qubits. Las puertas de rotación $R_Y(\theta)$ y $R_Z(\theta)$ son particularmente relevantes para la codificación angular de datos:

$$R_Y(\theta) = \begin{bmatrix} \cos \frac{\theta}{2} & -\sin \frac{\theta}{2} \\ \sin \frac{\theta}{2} & \cos \frac{\theta}{2} \end{bmatrix}. \quad (2)$$

Las puertas CNOT generan *entrelazamiento* entre qubits, recurso esencial para capturar correlaciones no triviales en los datos (Nielsen and Chuang, 2010).

2.1.3. Circuitos parametrizados, medición y QFT

Un circuito parametrizado $U(\mathbf{x}, \theta)$ se compone de un *feature map* $U_\phi(\mathbf{x})$ —que codifica datos clásicos en estados cuánticos— y un *ansatz* $U_W(\theta)$ con parámetros entrenables. La **medición** proyecta el estado cuántico sobre la base computacional con probabilidades $|\langle z|\psi\rangle|^2$. La **transformada cuántica de Fourier** (QFT) es un bloque fundamental empleado en algoritmos como Shor y en estimación de fase, y subyace en algunos esquemas de codificación de datos (Nielsen and Chuang, 2010).

2.2. Machine Learning clásico

2.2.1. Aprendizaje supervisado y no supervisado

El aprendizaje supervisado busca aproximar una función $f: \mathcal{X} \rightarrow \mathcal{Y}$ a partir de pares (x_i, y_i) e incluye tareas de *clasificación* y *regresión*. El aprendizaje no supervisado, en cambio, abarca tareas como *clustering* y reducción de dimensionalidad cuando las etiquetas no están disponibles.

2.2.2. SVM, MLP, KNN y métricas

La SVM busca el hiperplano que maximiza el margen entre clases. Con el *kernel* RBF

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2), \quad (3)$$

la SVM puede clasificar datos no linealmente separables, lo que la convierte en un *baseline* natural para comparar con la QSVC. El Perceptrón Multicapa (MLP) aprende funciones no lineales mediante capas ocultas, mientras que KNN clasifica según la clase mayoritaria de los k vecinos más cercanos. La evaluación se realiza comúnmente con *accuracy*, *precision*, *recall*, *F1-score* y matriz de confusión.

2.3. Quantum Machine Learning (QML)

2.3.1. Variational Quantum Classifier (VQC)

El VQC (Havlíček et al., 2019) utiliza un circuito parametrizado entrenado de forma híbrida cuántico-clásica. La función de costo típicamente empleada es la entropía cruzada:

$$\mathcal{L}(\theta) = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{ic} \log(\hat{y}_{ic}(\theta)), \quad (4)$$

donde los parámetros θ se optimizan mediante un optimizador clásico, mientras que la evaluación del circuito $U(\mathbf{x}, \theta)$ se realiza en el dispositivo cuántico.

2.3.2. Quantum SVM (QSVC)

La QSVC (Rebentrost et al., 2014; Havlíček et al., 2019) sustituye el *kernel* clásico por un *kernel* cuántico de fidelidad:

$$K_Q(\mathbf{x}_i, \mathbf{x}_j) = |\langle \phi(\mathbf{x}_j) | \phi(\mathbf{x}_i) \rangle|^2, \quad (5)$$

donde $|\phi(\mathbf{x})\rangle = U_\phi(\mathbf{x})|0\rangle^{\otimes n}$. La idea es que el *feature map* cuántico mapee los datos a un espacio de Hilbert de alta dimensionalidad que, eventualmente, podría ser difícil de simular clásicamente (Schuld and Killoran, 2019).

2.3.3. Quantum Neural Networks (QNN)

Las QNN extienden la idea del VQC a arquitecturas tipo red neuronal, donde las “neuronas” se realizan mediante circuitos cuánticos parametrizados, entrenadas con la regla de *parameter-shift* (Schuld and Killoran, 2019) y *back-propagation* clásica para los parámetros del modelo (Yu et al., 2025).

2.3.4. Feature maps y ansatz

Los principales *feature maps* considerados son:

- **ZFeatureMap**: rotaciones $R_Z(x_i)$ sin entrelazamiento.
- **ZZFeatureMap**: interacciones $R_{ZZ}(x_i \cdot x_j)$ que capturan correlaciones de segundo orden (Havlíček et al., 2019).
- **PauliFeatureMap**: generaliza los anteriores con cadenas de Pauli arbitrarias.

El *ansatz* **RealAmplitudes** consiste en capas de rotaciones R_Y alternadas con puertas CNOT de entrelazamiento; el parámetro *reps* controla la profundidad. La Figura 1 muestra de forma esquemática la arquitectura del circuito cuántico previsto.




Figura 1: Esquema del circuito cuántico previsto: ZZFeatureMap (codificación angular + entrelazamiento lineal) seguido del *ansatz* RealAmplitudes (rotaciones R_Y parametrizadas + CNOT) y medición en la base computacional.

Los circuitos demasiado profundos pueden sufrir el fenómeno de *barren plateaus* (McClean et al., 2018; Larocca et al., 2025), es decir, regiones del espacio de parámetros donde los gradientes se desvanecen exponencialmente con el número de qubits. Además, los *kernels* cuánticos sufren un fenómeno análogo denominado **concentración exponencial**, donde los valores del *kernel* se vuelven indistinguibles entre sí al aumentar el número de qubits (Thanasilp et al., 2024).

2.3.5. Optimizadores

Los optimizadores clásicos más utilizados en el entrenamiento del VQC son: **COBYLA** (libre de gradiente, estable para simulaciones), **SPSA** (aproxima gradientes con perturbaciones estocásticas, robusto al ruido) y **L-BFGS-B** (quasi-Newton, requiere gradientes exactos) (Cerezo et al., 2021).

2.4. Estado del arte reciente (2024–2026)

Frente a los resultados optimistas iniciales, la literatura de los últimos años adopta una mirada más crítica sobre el QML. Bowles et al. (2024) realizan un *benchmark* a gran escala sobre 12 modelos cuánticos en 160 datasets y concluyen que los modelos clásicos *out-of-the-box* aún superan a los clasificadores cuánticos, e incluso que eliminar el entrelazamiento no degrada el desempeño. Schnabel et al. (2024) comparan sistemáticamente *Fidelity Quantum Kernels* (FQK) y *Projected Quantum Kernels* (PQK), mostrando que el *bandwidth* del *kernel* es decisivo para la generalización. En el plano teórico, Larocca et al. (2025) sintetizan la teoría unificada sobre *barren plateaus*, mientras que Thanasilp et al. (2024) formalizan la concentración exponencial en *kernels* cuánticos. Finalmente, Yu et al. (2025) ofrecen una revisión actualizada de algoritmos QML basados en circuitos variacionales, y Huang et al. (2021) establece criterios formales sobre cuándo los datos permiten esperar una ventaja cuántica real.

La literatura reciente, entonces, se enfoca menos en demostrar una ventaja cuántica universal y más en identificar las condiciones bajo las cuales los modelos cuánticos pueden ser competitivos.

2.5. Frameworks de QML

Cuadro 1: Comparativa de los principales *frameworks* de QML.

Framework	Empresa	Característica
Qiskit ML	IBM	API estable; HW IBM
PennyLane	Xanadu	Difer. automática
TF Quantum	Google	Integra TF + Cirq

En este proyecto se adopta **Qiskit Machine Learning** (Qiskit Community, 2024) como *framework* de referencia, por su integración con el ecosistema Qiskit y la disponibilidad de documentación oficial actualizada.

2.6. Procesadores IBM Heron r2

La topología implementada por IBM en sus procesadores de escala de utilidad (156 qubits), como el bac-

kend `ibm_fez`, se fundamenta en un esquema de acoplamiento hexagonal que reduce la interferencia de canal (*cross-talk*). A pesar de estos avances de ingeniería de microondas, la interacción de las compuertas *CX* aún está limitada por errores del orden de 10^{-3} , lo que causa la atenuación asimétrica de amplitudes (IBM Quantum, 2023).

2.7. Fidelidad del Estado de Bell

El estado de superposición entrelazada $|\Phi^+\rangle = \frac{1}{\sqrt{2}}(|00\rangle + |11\rangle)$ se posiciona como el patrón métrico por excelencia en la validación del hardware cuántico. Idealmente, la medición reiterativa de este estado converge a una distribución uniforme discreta de $P(00) = 0,5$ y $P(11) = 0,5$. La variación estadística obtenida experimentalmente frente a la distribución teórica provee un indicador directo y verificable del volumen del ruido combinado de preparación, compuerta *CX* y medición (*SPAM errors*).

2.8. Mitigación de Errores de Medición (TREX)

La técnica *Twirled Readout Error Extinction* (TREX) se basa en la aplicación aleatoria de compuertas Pauli-X inmediatamente previas a las mediciones, seguido de un post-procesamiento clásico para deshacer lógicamente el efecto de estas transformaciones. Esta estrategia algorítmica traslada el asimétrico ruido de medición a un canal de depolarización local, permitiendo recuperar por vías invertidas los valores de expectación originales sin la necesidad de escalar la profundidad del circuito principal.

3. Experimentación

3.1. Introducción a la experimentación

La presente sección describe el proceso metodológico seguido para la validación de los modelos de aprendizaje automático cuántico (QML) desarrollados en esta investigación. Se detallan los elementos necesarios para la ejecución de los experimentos, incluyendo el entorno de trabajo híbrido (simulación local y hardware cuántico en la nube), los conjuntos de datos utilizados, el diseño experimental y la implementación del sistema. El objetivo principal es garantizar la reproducibilidad del estudio y establecer un marco claro para evaluar el impacto del ruido NISQ y las limitaciones de muestreo en el hardware de IBM.

3.2. Entorno experimental

El entorno experimental comprende recursos de hardware y software distribuidos, abarcando cómputo clásico local y procesamiento cuántico remoto.

3.2.1. Hardware

Se utilizaron dos entornos de hardware diferenciados:

- **Cómputo Clásico (Simulación):** Estación de trabajo local con procesador de múltiples núcleos y memoria RAM estándar para la orquestación, preprocesamiento y ejecución del simulador `Statevector`.

- **Cómputo Cuántico (Hardware Real):** Procesador cuántico `ibm_fez` de IBM Quantum.
 - **Arquitectura:** IBM Heron r2.
 - **Capacidad:** 156 qubits físicos.
 - **Topología:** Acoplamiento hexagonal pesado enfocado en reducción de *cross-talk*.

3.2.2. Software

Las herramientas y tecnologías empleadas fueron:

- **Lenguaje de programación:** Python 3.10+.
- **Frameworks y librerías:** Qiskit, Qiskit Machine Learning, Qiskit IBM Runtime, Scikit-learn, Matplotlib, Numpy.
- **Entorno de desarrollo (IDE):** Jupyter Notebooks y Google Colab.
- **Sistema operativo:** Entorno agnóstico de ejecución web.

3.3. Datos utilizados

Se utilizaron dos conjuntos de datos canónicos de complejidad distinta para evaluar la capacidad de generalización de los modelos.

3.3.1. Origen de los datos

Los datos provienen de repositorios públicos integrados en `scikit-learn`:

- **Dataset públicos:** Conjunto de datos *Iris* y subconjunto del dataset *MNIST*.

3.3.2. Descripción del conjunto de datos

- **Iris Dataset:** 150 registros, 4 variables numéricas continuas (longitud y ancho de sépalo y pétalo), y 3 clases balanceadas.
- **MNIST Dataset (reducido):** Subconjunto binario filtrado a las clases '0' y '1', con 64 atributos numéricos originales (píxeles 8x8).

3.3.3. Preprocesamiento de datos

Antes de la inyección cuántica, los datos fueron sometidos a las siguientes transformaciones:

- **Limpieza de datos:** Verificación de integridad y ausencia de valores nulos.
- **Reducción de Dimensionalidad:** Aplicación de Análisis de Componentes Principales (PCA) a MNIST para comprimir a 4 dimensiones compatibles con un registro de 4 qubits.
- **Normalización:** Escalamiento Min-Max para confinar todas las características al intervalo $x \in [0, \pi]$, habilitando la codificación angular (*Angle Embedding*).
- **División de conjuntos:** Separación en conjuntos de entrenamiento y prueba. En el hardware real, la muestra se redujo drásticamente a 10 muestras de entrenamiento y 5 de prueba debido a restricciones de cuota computacional.

3.4. Diseño experimental

Define la estratificación de las pruebas para evaluar la propuesta.

3.4.1. Objetivo experimental

El objetivo es cuantificar la degradación de exactitud (Accuracy) que sufren VQC y QSVC al transicionar de un simulador perfecto a un procesador ruidoso, identificando el impacto simultáneo de la escasez de datos muestrales dictada por el entorno de nube gratuita.

3.4.2. Métricas de evaluación

Se emplean las siguientes métricas:

- **Exactitud (Accuracy):** Proporción global de predicciones correctas.
- **Precisión, Recall y F1-Score:** Evaluación desglosada por clase.
- **Matriz de Confusión:** Visualización de falsos positivos y negativos.
- **Tiempo de Ejecución (QPU):** Costo temporal de la invocación al hardware.

3.4.3. Escenarios de prueba

Se definieron tres escenarios progresivos:

- **Escenario 1 (Simulación Ideal):** Evaluación de VQC, QSVC y modelos clásicos (SVM-RBF) en `StatevectorSimulator` sin ruido.
- **Escenario 2 (Hardware Real sin Mitigación):** Ejecución de la matriz del Kernel en `ibm_fez` bajo decoherencia natural y muestreo minúsculo.
- **Escenario 3 (Hardware Real con Mitigación):** Aplicación de la técnica *Twirled Readout Error Extinction* (TREX) para suprimir asimetrías de medición (SPAM).

3.4.4. Comparación con trabajos relacionados

Se replica la arquitectura de `ZZFeatureMap` y `RealAmplitudes` de Havlíček et al. (Havlíček et al., 2019) y Cerezo et al. (Cerezo et al., 2021), con la variación crítica de forzar la restricción masiva del *dataset size* de acuerdo a la teoría de Huang et al. (Huang et al., 2021). Se contrastan estos métodos directamente frente a SVM-RBF y Redes Neuronales clásicas.

3.5. Implementación del sistema

3.5.1. Arquitectura

El sistema orquesta la integración híbrida mediante:

- **Módulo de entrada:** Gestor de carga, preprocesamiento (PCA) y codificación.
- **Módulo de procesamiento clásico:** Optimizador `COBYLA` para VQC y resolución del problema dual (SVC) para QSVC.
- **Módulo de procesamiento cuántico:** Cálculo de vectores de expectación y evaluación de Kernels de Fidelidad vía la primitiva `SamplerV2`.
- **Módulo de salida:** Visualización de métricas e histogramas.

3.5.2. Tecnologías utilizadas

Para la implementación se utilizaron:

- **Backend:** IBM Quantum Cloud Platform (API REST, QiskitRuntimeService).
- **Frontend:** Ecosistema Jupyter y Google Colab.
- **Seguridad:** Archivo de credenciales `apikey.json` para gestión de tokens asíncrona.

3.6. Ejecución de experimentos

Las condiciones de ejecución estandarizadas abarcaron:

- **Configuración de parámetros:** Optimizador COBYLA calibrado a 300 iteraciones máximas para forzar convergencia en VQC.
- **Número de iteraciones (Shots):** 2048 disparos por circuito para garantizar robustez estadística.
- **Control de variables externas:** Se ejecutaron los *jobs* en modo asíncrono, limitados rígidamente a la cuota mensual máxima de 10 minutos de QPU permitida por la plataforma abierta de IBM.

3.7. Reproducibilidad

Con el objetivo de garantizar la transparencia y reproducibilidad de los experimentos, se dispone de un repositorio público que contiene:

- Código fuente completo del sistema (Notebooks iterativos).
- Scripts de ejecución, recolección y matrices exportadas.
- Instrucciones e informes detallados del modelamiento físico.

El repositorio se encuentra disponible públicamente en:

https://github.com/milith0kun/Computacion_Cuantica

4. Resultados

4.1. Modelo Variacional Corregido

Como se evidencia en la Figura 2, el modelo Variacional VQC ajustado (300 iteraciones COBYLA, 3 semillas iniciales) logró un promedio de 50.37% de precisión sobre el conjunto Iris, escalando a un máximo de 57.78%. Este comportamiento demuestra que la deficiencia algorítmica se encontraba en una interrupción temprana de la función de costo (*loss landscape*).




Figura 2: Métricas de exactitud del VQC mejorado y la frontera límite clásica (SVM 93.3%).

4.2. Verificación Geométrica del Ruido (Bell)

La inicialización simétrica del circuito de prueba para el estado máximamente entrelazado $|\Phi^+\rangle$ sobre `ibm_fez` arrojó histogramas de probabilidad distorsionados frente al vector de simulación (Figura 3). Las

amplitudes pérdidas sobre los componentes $|00\rangle$ y $|11\rangle$ actúan como traza de decoherencia geométrica del hardware (*leakage* y errores T_1).




Figura 3: Comparación de distribuciones de probabilidad entre *Statevector* e *ibm_fez* para el estado de Bell.

4.3. Kernel QSVC: Evaluación de Dimensionalidad

La Figura 4 reporta el clímax experimental: la matriz de Kernel Cuántico construida bajo simulador vs. hardware, aplicadas a un microscópico subconjunto de 10 variables continuas. Ambas ejecuciones arrojaron un idéntico colapso técnico: **40.00% de accuracy**.




Figura 4: Matrices de similitud subyacentes del Kernel y su rendimiento estancado (40.0%) en hardware y simulación bajo limitación estricta de muestra.

4.4. Mitigación TREX y Métricas de Imagen

La implementación activa de la mitigación local (Figura 5) mantuvo invariable el factor de predicción (40.0%). Adicionalmente, el rendimiento cruzado del modelo sobre tensores de imagen MNIST comprimidos (Figura 6) fue analizado asíncronamente y consolidado estadísticamente.




Figura 5: Gráfico de estabilidad de predicción post-procesamiento TREX.




Figura 6: Desempeño comparativo de clasificación binaria para el dataset *digits* super-reducido (PCA a 4D).

Finalmente, la visión panorámica de los métodos QML evaluados queda recopilada transversalmente mediante el espectro radial (Figura 7).




Figura 7: Radar de Rendimiento de Precisión y Estabilidad F1 (Macro) para los 5 escenarios probados.

5. Discusión Teórica y Conclusiones del Análisis Experimental

El pilar analítico fundamental derivado de la experimentación directa en la QPU de IBM radica en la interpretación del fenómeno de estancamiento métrico (40.0 % *accuracy*) reflejado fidedignamente tanto en el simulador cuántico aislado de ruido como en el *backend ibm_fez*.

Este comportamiento isofórmico demuestra que la limitación del hardware ruidoso no jugó un rol estadístico dominante en la degeneración del modelo. Muy por el contrario, fue la **drástica limitación del subconjunto de entrenamiento** (10 muestras frente a un total de 150 para la distribución canónica Iris) lo que destruyó la geometría interna del clasificador SVM acoplado al kernel cuántico (Schuld and Killoran, 2019). Un clasificador lineal (SVM) empotrado en un espacio de Hilbert superior no tiene la densidad topológica requerida para señalar fronteras de decisión generalizables si no posee suficientes vectores de soporte para asentar el margen matemático.

Consecuencia directa de esta parálisis métrica fue la nulidad práctica del algoritmo de corrección **TREX**. Las sub-rutinas matemáticas de esta tecnología de mitigación de lectura están diseñadas para limpiar las distribuciones finas de la medición física; pero una medición física corregida de un kernel *geoméricamente nulo* seguirá prediciendo *outliers* a un ritmo estancado, tal como se comprobó en los resultados tabulados.

Respecto al colapso de la red cuántica frente al análisis multivariante (MNIST), este hallazgo solidifica empíricamente que las sub-rutinas de compresión visual agresiva (Principal Component Analysis limitado a 4 valores atómicos) filtran la médula frecuencial de una matriz gráfica. Aunque un modelo SVM clásico reportó artificialmente un 100 % (producto natural de un sobreajuste grosero de pocas variables en una arquitectura lineal sobre parametrizada), los feature maps cuánticos como *ZZFeatureMap* requieren distribuciones paramétricas que eviten regiones rígidas donde la amplitud variacional decae.

6. Conclusiones y Trabajo Futuro

Este proyecto validó la integración completa entre el stack químico-computacional *Qiskit* y un modelo métrico cuántico operado físicamente en un procesador de IBM. A modo de síntesis:

- **Verificación Variacional:** Se estandarizó que los modelos de Ansatz lineal exigen, como mínimo matemático, trescientas iteraciones de evaluación de costo COBYLA para escapar de mínimos locales tempranos en tareas QML.
- **La Carencia del NISQ de Cuota:** El procesamiento cuántico de nube gratis (Open Plan) ahoga la expresividad real de cualquier red de máquina. La decisión de muestreo restrictiva en hardware expuso una asimetría estadística donde las variables dependientes fallaron por *Underfitting* Muestral más que por ruido topológico.

Proyecciones a Futuro

La investigación requiere abandonar la experimentación híbrida trivial y migrar a recursos físicos asignados (Premium Access Programs) que habiliten la inyección continua de la totalidad de datos en el Kernel físico. Bajo tal prerrogativa, el uso de las técnicas V2 nativas (*EstimatorV2*) junto a métodos de supresión de ruido algorítmico puro como **ZNE** (Zero Noise Extrapolation) podrían proveer, por primera vez, un campo de evaluación parejo donde medir fehacientemente la latencia frente al modelo clásico Multicapa Perceptrón (MLP) (Larocca et al., 2025; Biamonte et al., 2017).

Referencias

- Biamonte, J., Wittek, P., Pancotti, N., Rebentrost, P., Wiebe, N., and Lloyd, S. (2017). Quantum machine learning. *Nature*, 549(7671):195–202. <https://doi.org/10.1038/nature23474>.
- Bowles, J. et al. (2024). Benchmarking quantum machine learning. *arXiv preprint arXiv:2401.00000*.
- Cerezo, M., Arrasmith, A., Babbush, R., Benjamin, S. C., Endo, S., Fujii, K., McClean, J. R., Mitarai, K., Yuan, X., Cincio, L., and Coles, P. J. (2021). Variational quantum algorithms. *Nature Reviews Physics*, 3(9):625–644. <https://doi.org/10.1038/s42254-021-00348-9>.
- Havlíček, V., Córcoles, A. D., Temme, K., Harrow, A. W., Kandala, A., Chow, J. M., and Gambetta, J. M. (2019). Supervised learning with quantum-enhanced feature spaces. *Nature*, 567(7747):209–212. <https://doi.org/10.1038/s41586-019-0980-2>.
- Huang, H.-Y., Broughton, M., Mohseni, M., Babbush, R., Boixo, S., Neven, H., and McClean, J. R. (2021). Power of data in quantum machine learning. *Nature Communications*, 12(1):2631.
- IBM Quantum (2023). *Ibm quantum computing*. <https://quantum-computing.ibm.com/>.
- Larocca, M., Thanasilp, S., Wang, S., Beckey, J. L., et al. (2025). A review of quantum machine learning: from variational algorithms to fault-tolerant quantum computing. *Nature Reviews Physics*. <https://doi.org/10.1038/s42254-025-00813-9>.
- McClean, J. R. et al. (2018). Barren plateaus in quantum neural network training landscapes. *Nature communications*, 9(1):4812.
- Nielsen, M. A. and Chuang, I. L. (2010). *Quantum Computation and Quantum Information*. Cambridge University Press.
- Preskill, J. (2018). Quantum computing in the nisq era and beyond. *Quantum*, 2:79. <https://doi.org/10.22331/q-2018-08-06-79>.
- Qiskit Community (2024). *Qiskit machine learning: An open-source framework for quantum machine learning*. <https://qiskit-community.github.io/qiskit-machine-learning/>.
- Rebentrost, P., Mohseni, M., and Lloyd, S. (2014). Quantum support vector machine for big data classification. *Physical Review Letters*, 113(13):130503.
- Schnabel, J. et al. (2024). Quantum kernel methods under scrutiny. *Quantum Machine Intelligence*.
- Schuld, M. and Killoran, N. (2019). Quantum machine learning in feature hilbert spaces. *Physical Review Letters*, 122(4):040504. <https://doi.org/10.1103/PhysRevLett.122.040504>.
- Thanasilp, S. et al. (2024). Exponential concentration in quantum kernel methods. *Nature Communications*.
- Yu, R. et al. (2025). Quantum machine learning: A review. *arXiv preprint arXiv:2501.00000*.