



UNIVERSIDAD NACIONAL DE SAN ANTONIO ABAD DEL CUSCO
Escuela Profesional de Ingeniería Informática y de Sistemas



Implementación de un Modelo de Aprendizaje Automático Cuántico

Utilizando [Qiskit Machine Learning](#) sobre hardware cuántico real IBM Quantum

Capítulo de Experimentación

IBM Heron r2 · ibm_fez

GRUPO 1

Saire Bustamante

Lozano Llactahuaman

Puma Potosino

Junio 2026

Estructura de la Presentación

01 Fundamentos Teóricos
Qubits, puertas, QML, NISQ

02 Entorno y Datos
Hardware, software, datasets

03 Diseño Experimental
3 escenarios progresivos

04 Exp. 1: Baseline vs. VQC
Clásico vs. variacional

05 Exp. 2: Estado de Bell
Verificación de fidelidad HW

06 Exp. 3: QSVC Sim. vs. HW
Degradación del kernel

07 Exp. 4: Mitigación TREX
Corrección de errores SPAM

08 Exp. 5: MNIST Hardware
Resultado atípico

09 Resumen Comparativo
11 modelos, tabla + radar

10 Conclusiones y Futuro
Hallazgos y líneas de trabajo

Computación Cuántica: Conceptos Clave

Qubits y Superposición

El qubit existe en superposición de $|0\rangle$ y $|1\rangle$:

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle$$

Un sistema de n qubits vive en un espacio de Hilbert de dimensión 2^n .

Puertas Cuánticas

Operaciones unitarias. Las rotaciones $R_Y(\theta)$ y $R_Z(\theta)$ codifican datos angularmente.

Las puertas **CNOT** generan entrelazamiento, recurso esencial para correlaciones no triviales.

Circuitos Parametrizados

- **Feature Map** $U_\phi(x)$ — codifica datos
- **Ansatz** $U_W(\theta)$ — parámetros entrenables
- **Medición** — proyecta sobre base Z


Feature Maps usados: ZZFeatureMap (interacciones R_{ZZ} de segundo orden) + Ansatz RealAmplitudes (R_Y + CNOT). Optimizador COBYLA (libre de gradiente, 300 iter). Shots: 2048 por circuito.

Circuitos Cuánticos del VQC

ZZFeatureMap (Codificación)

Mapea características clásicas x a ángulos de rotación.


ZZFeatureMap DESCOMPUESTO en puertas basicas (H, P, CX)



RealAmplitudes Ansatz (Entrenamiento)

Parámetros θ optimizables y entrelazamiento lineal.

VQC Completo = ZZFeatureMap(datos) + RealAmplitudes(pesos) + Medicion



Modelos de Quantum Machine Learning

VQC — Variational Quantum Classifier

Circuito parametrizado entrenado de forma híbrida. La entropía cruzada se minimiza con un optimizador clásico; el circuito se evalúa en el QPU.

Problema: circuitos profundos sufren **barren plateaus** — gradientes que se desvanecen exponencialmente.

QSVC — Quantum SVM Classifier

Kernel cuántico de fidelidad:

$$K_Q(x_i, x_j) = |\langle \varphi(x_j) | \varphi(x_i) \rangle|^2$$

Feature map mapea datos a espacio de Hilbert de dimensión $2^4 = 16$, potencialmente difícil de simular clásicamente.

Estado del Arte (2024–2026)

Bowles et al. (2024): benchmark de 12 modelos cuánticos en 160 datasets concluye que los clásicos *out-of-the-box* aún superan a los cuánticos.

Mitigación TREX

Twirled Readout Error Extinction: puertas Pauli-X aleatorias antes de medir, trasladando el ruido asimétrico a un canal de depolarización local invertible.

Infraestructura Híbrida: Clásica + Cuántica

Cómputo Clásico

CPU	AMD Ryzen 7 9700X (8 cores)
RAM	32 GB DDR5
SSD	1 TB NVMe Kingston
GPU	NVIDIA GTX 1050 Ti (4 GB)
Entorno	Jupyter / Google Colab

Hardware Cuántico Real

Sistema	ibm_fez
Chip	IBM Heron r2
Qubits	156 qubits físicos
Topología	Hexagonal pesado (anti-crosstalk)
Acceso	IBM Quantum Cloud (gratis)

Restricción: Cuota gratuita ~10 min/mes de QPU. Consumo total: ~594s (~9.9 min). Subset forzado: 13 train + 9 test. Stack: Python 3.10+, Qiskit, Qiskit ML, Qiskit Runtime, Scikit-learn.

Conjuntos de Datos y Preprocesamiento

Iris Dataset (3 clases)

Registros	150 muestras, 4 variables
Clases	Setosa, Versicolor, Virginica
Split normal	105 train / 45 test
Split HW	13 train / 9 test
Normalización	Min-Max $\rightarrow [0, \pi]$

MNIST Reducido (binario: 0 vs. 1)

Original	64 atributos (8×8 px)
PCA	Compresión a 4D (73.4% var.)
Clases	2 (dígitos "0" y "1")
Split HW	13 train / 9 test
Codificación	Angle Embedding

Restricción crítica: Con 9 muestras de test, cada muestra = $\pm 11.1\%$ del accuracy.

Codificación Angular de Características Clásicas


Pipeline de Mapeo a Qubits

El dataset Iris (4D) se normaliza en el rango $[0, \pi]$ para representar rotaciones sobre la esfera de Bloch.

Cada característica x_i se asocia con un qubit, aplicando compuertas de rotación parametrizadas por el feature map.

Esto explota el espacio de estados de Hilbert para buscar fronteras de decisión no lineales en el espacio clásico.

Circuito de Codificación (Detallado)



Escenarios de Prueba Progresivos

1 Simulación Ideal

Statevector Simulator (Sin Ruido)

- **Modelos:** SVM, MLP, KNN clásicos + VQC y QSVC cuánticos.
- **Muestras:** Dataset completo (105 de entrenamiento / 45 de prueba).
- **Objetivo:** Establecer la precisión teórica óptima libre de perturbaciones físicas.

Sin ruido

Datos completos

2 HW sin Mitigación

QPU Física Real (ibm_fez)

- **Procesador:** IBM Heron r2 (156 qubits físicos con topología hexagonal pesada).
- **Restricción:** Muestra reducida (13 entrenamiento / 9 prueba) por límite de cuota.
- **Efectos:** Exposición a ruido de fase, decoherencia T1/T2 y errores de compuertas.

Con ruido

Datos mínimos

3 HW + TREX

QPU Real con Mitigación SPAM

- **Técnica:** Twirled Readout Error Extinction mediante promediado de Pauli.
- **Enfoque:** Corrección de errores de lectura al final de la medición.
- **Evaluación:** Analizar si la corrección SPAM rescata un kernel geoméricamente colapsado.

Mitigado

Datos mínimos

Métricas:

Accuracy

F1-Score macro

Tiempo QPU

Matriz de confusión

Línea Base Clásica vs. VQC Simulado

Modelos Clásicos (Iris completo)

MODELO	ACCURACY	F1
SVM-RBF	93.33%	0.933
MLP	93.33%	0.933
KNN	93.33%	0.933

VQC (3 semillas, COBYLA 300 iter.)

SEMILLA	ACCURACY	ITER.	TIEMPO
42	55.56%	152	36.1s
123	60.00%	164	41.1s
789	46.67%	130	32.5s


Brecha Cuántico-Clásica

-33 pp

VQC (60%) vs. SVM (93.3%)


El *loss landscape* variacional presenta mínimos locales difíciles de superar. Consistente con Bowles et al. (2024).

Accuracy, Convergencia VQC y F1-Score por Modelo




Circuito y Distribución de Probabilidad: Simulador vs. ibm_fez

Circuito de Bell (H + CNOT)



Histograma de Probabilidad



Generación del estado entrelazado $|\Phi^+\rangle = 1/\sqrt{2} (|00\rangle + |11\rangle)$. Las pequeñas fugas hacia $|01\rangle$ y $|10\rangle$ en hardware real se deben a errores de lectura (SPAM) y relajación térmica T_1 .

QSVC: Simulador vs. Hardware Real

Resultados del Kernel QSVC

ENTORNO	ACCURACY	F1	TIEMPO
Simulador (full)	77.78%	0.777	19.7s
Simulador (subset)	33.33%	0.324	0.46s
HW ibm_fez	11.11%	0.111	182s

Degradación dual:

- 1. Escasez muestral: 77.8% → 33.3% (-44 pp)
- 2. Ruido NISQ: 33.3% → 11.1% (-22 pp)


Degradación total

-66 pp

77.8% (sim. full) → 11.1% (hw)

= 1 de 9 muestras correctas

Circuito Compute-Uncompute y Matrices de Kernel Cuántico



El kernel cuántico calcula $K(x_i, x_j) = |\langle 0^n | U_{\phi}^{\dagger}(x_j) U_{\phi}(x_i) | 0^n \rangle|^2$. En hardware real, la decoherencia destruye la estructura diagonal del kernel de entrenamiento.

Mitigación de Errores: TREX

ACCURACY POST-TREX

11.11%

Sin cambio respecto a sin mitigación




Se requieren técnicas más agresivas: **ZNE** (Zero Noise Extrapolation) o **PEC** (Probabilistic Error Cancellation) que operen sobre el ruido de compuerta.

¿Por qué TREX no funcionó?

- TREX corrige errores de lectura (SPAM), no ruido de compuerta
- El kernel está **geométricamente colapsado** por ruido coherente + escasez muestral
- La corrección de lectura no recupera información perdida en compuertas intermedias
- El circuito compute-uncompute acumula errores en toda su profundidad antes de la medición

Estabilidad de Predicción Post-TREX

Accuracy invariable (11.11%) respecto al escenario sin mitigación. La corrección SPAM no recupera un kernel colapsado.



MNIST en Hardware: Resultado Atípico

MNIST Binario (0 vs. 1), PCA → 4D

MODELO	ACCURACY	F1	TIEMPO
SVM-RBF (clásico)	100.0%	1.000	0.01s
QSVC (simulador)	77.78%	0.775	0.43s
QSVC (ibm_fez)	88.89%	0.889	205s


HW superó al Simulador



No es ventaja cuántica. Con 9 muestras test ($\pm 11.1\%$ cada una), el ruido estocástico actuó como regularización implícita. Artefacto estadístico por baja resolución muestral. Con datasets más grandes, el simulador superaría al hardware.

Clasificación MNIST (0 vs. 1): Clásico, Simulador y Hardware

Dataset binario comprimido con PCA a 4D (73.44% varianza). Resultado atípico: HW (88.9%) supera al simulador (77.8%).




Comparación Global de Todos los Modelos

TIPO	MODELO	ACCURACY	F1 (MACRO)	ENTORNO
Clásico	SVM-RBF (Iris)	93.33%	0.933	Local
Clásico	MLP (Iris)	93.33%	0.933	Local
Clásico	KNN (Iris)	93.33%	0.933	Local
Simulador	VQC (Iris)	60.00%	0.481	Statevector
Simulador	QSVC (Iris full)	77.78%	0.777	Statevector
Simulador	QSVC (Iris subset)	33.33%	0.324	Statevector
Hardware	QSVC sin mitigación	11.11%	0.111	ibm_fez
Hardware	QSVC + TREX	11.11%	0.111	ibm_fez
Clásico	SVM-RBF (MNIST)	100.00%	1.000	Local
Simulador	QSVC (MNIST)	77.78%	0.775	Statevector
Hardware	QSVC (MNIST)	88.89%	0.889	ibm_fez

Comparación Global: Clásico vs. Simulador vs. Hardware

Barras de accuracy por modelo y gráfico radar de rendimiento multidimensional (Accuracy Iris, Accuracy MNIST, Fidelidad Kernel).



Conclusiones de la Experimentación

- 01 Viabilidad demostrada:** Se validó la integración completa entre Qiskit y el procesador IBM Heron r2 (ibm_fez, 156 qubits). La fidelidad de Bell de 0.9834 confirma la calidad del hardware.
- 02 Impacto dual cuantificado:** La escasez muestral causa **-44 pp** y el ruido NISQ causa **-22 pp** adicionales. Sin mitigación avanzada (ZNE/PEC), los kernels cuánticos son inviables en hardware real.
- 03 Brecha cuántico-clásica:** Los modelos clásicos (SVM-RBF, MLP, KNN = 93.3%) superan al mejor QML (VQC = 60%). Consistente con Bowles et al. (2024): NISQ no ofrece ventaja competitiva actual.
- 04 Reproducibilidad:** Código completo, datasets, matrices de kernel y resultados disponibles en el repositorio público de GitHub.



Líneas de Trabajo Futuro

01

Escala Muestral

Migrar a IBM Premium Access para eliminar la restricción de cuota e inyectar datasets completos.

02

Mitigación Avanzada

Implementar ZNE y PEC con la primitiva EstimatorV2 para operar sobre ruido de compuerta.

03

Benchmark Justo

Replicar Bowles et al. (2024) con 160 datasets en hardware real para detectar nichos de ventaja.

REPOSITORIO PÚBLICO

github.com/milith0kun/Computacion_Cuantica

Grupo 1

Saire Bustamante Lozano Llactahuaman Puma Potosino

Junio 2026

