



Implementación de un modelo de aprendizaje automático cuántico utilizando Qiskit Machine Learning

Edmil Jampier Saire Bustamante (174449)
Medaly Lozano Llacctahuaman (195040)
José Francisco Puma Potosino (164248)

Resumen. El proyecto consiste en diseñar e implementar un modelo de clasificación basado en aprendizaje automático cuántico (*Quantum Machine Learning*, QML) usando el *framework* Qiskit Machine Learning, y compararlo con modelos clásicos equivalentes. Como modelos cuánticos se eligieron el Clasificador Cuántico Variacional (VQC) y la Máquina de Vectores de Soporte Cuántica (QSVC), por ser los más estudiados en la literatura y los que mejor se ajustan a simulación con pocos qubits; como *baselines* clásicos se utilizan SVM-RBF, MLP y KNN. El dataset principal es Iris, cuyas 4 características permiten una codificación natural en 4 qubits, y se incluye una versión reducida de MNIST para evaluar generalización. En este documento se presenta el planteamiento general del proyecto, la fundamentación teórica y el diseño inicial del circuito cuántico (*feature map* y *ansatz*) que se implementará en las siguientes fases.

Palabras clave: QML, VQC, QSVC, Qiskit Machine Learning, circuitos variacionales, *kernel* cuántico, *feature map*, NISQ.

1. Objetivo general

Diseñar un modelo de aprendizaje automático basado en principios de computación cuántica que permita evaluar su desempeño frente a métodos clásicos equivalentes sobre conjuntos de datos representativos.

2. Objetivos específicos

1. Comprender los fundamentos teóricos del aprendizaje automático cuántico (QML), así como los conceptos básicos de computación cuántica que lo sustentan.
2. Realizar una revisión sistemática de la literatura siguiendo la metodología PRISMA sobre los principales modelos de QML (VQC, QSVC y QNN) y los *frameworks* disponibles para su implementación.
3. Seleccionar justificadamente el tipo de modelo cuántico a implementar, considerando su viabilidad sobre simuladores y la naturaleza de los datos a utilizar.
4. Elegir uno o más datasets pequeños y representativos adecuados para la codificación en pocos qubits.
5. Definir el diseño preliminar del circuito cuántico (*feature map* y *ansatz*) y de los modelos clásicos de referencia que serán utilizados como *baseline*.

3. Justificación

El aprendizaje automático cuántico (*Quantum Machine Learning*, QML) es un campo emergente que busca aprovechar las propiedades de la mecánica cuántica —particularmente la **superposición** y el **entrelazamiento**— para acelerar tareas de aprendizaje y optimización (Biamonte et al., 2017). Con el desarrollo de *frameworks* maduros como Qiskit Machine Learning (Qiskit, 2024), hoy es factible implementar y evaluar modelos cuánticos tanto en simuladores clásicos como en hardware cuántico real.

En los últimos años se han propuesto diversos modelos representativos de clasificación cuántica, entre los que destacan el VQC (Havlíček et al., 2019) y el QSVC (Rebentrost et al., 2014). Estos modelos se enmarcan dentro de los algoritmos variacionales cuántico-clásicos (Cerezo et al., 2021), especialmente adecuados para la era NISQ (*Noisy Intermediate-Scale Quantum*) (Preskill, 2018).

Sin embargo, la demostración de una *ventaja cuántica* práctica sobre métodos clásicos sigue siendo un problema abierto. Estudios recientes de *benchmarking* a gran escala (Bowles et al., 2024; Schnabel et al., 2024) sugieren que, para datos clásicos de baja dimensiona-

lidad, los modelos clásicos aún superan a los clasificadores cuánticos disponibles. En ese contexto, una implementación propia resulta valiosa desde el punto de vista académico: permite contrastar dichos resultados, observar de primera mano las limitaciones del QML actual y trabajar con las herramientas que hoy utiliza la comunidad científica del área.

4. Marco teórico

4.1. Computación cuántica

4.1.1. Qubits y estados cuánticos

El qubit es la unidad fundamental de información cuántica (Nielsen y Chuang, 2010). A diferencia del bit clásico, puede existir en una superposición de los estados $|0\rangle$ y $|1\rangle$:

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle, \quad |\alpha|^2 + |\beta|^2 = 1, \quad (1)$$

donde $\alpha, \beta \in \mathbb{C}$ son amplitudes de probabilidad. Un sistema de n qubits vive en un espacio de Hilbert de dimensión 2^n , propiedad que constituye la base del potencial computacional cuántico.

4.1.2. Puertas cuánticas

Las puertas cuánticas son operaciones unitarias que transforman el estado de los qubits. Las puertas de rotación $R_Y(\theta)$ y $R_Z(\theta)$ son particularmente relevantes para la codificación angular de datos:

$$R_Y(\theta) = \begin{bmatrix} \cos \frac{\theta}{2} & -\sin \frac{\theta}{2} \\ \sin \frac{\theta}{2} & \cos \frac{\theta}{2} \end{bmatrix}. \quad (2)$$

Las puertas CNOT generan *entrelazamiento* entre qubits, recurso esencial para capturar correlaciones no triviales en los datos (Nielsen y Chuang, 2010).

4.1.3. Circuitos parametrizados, medición y QFT

Un circuito parametrizado $U(\mathbf{x}, \boldsymbol{\theta})$ se compone de un *feature map* $U_\phi(\mathbf{x})$ —que codifica datos clásicos en estados cuánticos— y un *ansatz* $U_W(\boldsymbol{\theta})$ con parámetros entrenables. La **medición** proyecta el estado cuántico sobre la base computacional con probabilidades $|\langle z|\psi\rangle|^2$. La **transformada cuántica de Fourier** (QFT) es un bloque fundamental empleado en algoritmos como Shor y en estimación de fase, y subyace en algunos esquemas de codificación de datos (Nielsen y Chuang, 2010).

4.2. Machine Learning clásico

4.2.1. Aprendizaje supervisado y no supervisado

El aprendizaje supervisado busca aproximar una función $f: \mathcal{X} \rightarrow \mathcal{Y}$ a partir de pares (x_i, y_i) e incluye tareas de *clasificación* y *regresión*. El aprendizaje no supervisado, en cambio, abarca tareas como *clustering* y reducción de dimensionalidad cuando las etiquetas no están disponibles.

4.2.2. SVM, MLP, KNN y métricas

La SVM busca el hiperplano que maximiza el margen entre clases. Con el *kernel* RBF

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2), \quad (3)$$

la SVM puede clasificar datos no linealmente separables, lo que la convierte en un *baseline* natural para comparar con la QSVC. El Perceptrón Multicapa (MLP) aprende funciones no lineales mediante capas ocultas, mientras que KNN clasifica según la clase mayoritaria de los k vecinos más cercanos. La evaluación se realiza comúnmente con *accuracy*, *precision*, *recall*, *F1-score* y matriz de confusión.

4.3. Quantum Machine Learning (QML)

4.3.1. Variational Quantum Classifier (VQC)

El VQC (Havlíček et al., 2019) utiliza un circuito parametrizado entrenado de forma híbrida cuántico-clásica. La función de costo típicamente empleada es la entropía cruzada:

$$\mathcal{L}(\boldsymbol{\theta}) = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{ic} \log(\hat{y}_{ic}(\boldsymbol{\theta})), \quad (4)$$

donde los parámetros $\boldsymbol{\theta}$ se optimizan mediante un optimizador clásico, mientras que la evaluación del circuito $U(\mathbf{x}, \boldsymbol{\theta})$ se realiza en el dispositivo cuántico.

4.3.2. Quantum SVM (QSVC)

La QSVC (Rebentrost et al., 2014; Havlíček et al., 2019) sustituye el *kernel* clásico por un *kernel* cuántico de fidelidad:

$$K_Q(\mathbf{x}_i, \mathbf{x}_j) = |\langle \phi(\mathbf{x}_j) | \phi(\mathbf{x}_i) \rangle|^2, \quad (5)$$

donde $|\phi(\mathbf{x})\rangle = U_\phi(\mathbf{x})|0\rangle^{\otimes n}$. La idea es que el *feature map* cuántico mapee los datos a un espacio de Hilbert de alta dimensionalidad que, eventualmente, podría ser difícil de simular clásicamente (Schuld et al., 2019).

4.3.3. Quantum Neural Networks (QNN)

Las QNN extienden la idea del VQC a arquitecturas tipo red neuronal, donde las “neuronas” se realizan mediante circuitos cuánticos parametrizados, entrenadas con la regla de *parameter-shift* (Schuld et al., 2019) y *back-propagation* clásica para los parámetros del modelo (Yu et al., 2025).

4.3.4. Feature maps y ansatz

Los principales *feature maps* considerados son:

- **ZFeatureMap**: rotaciones $R_Z(x_i)$ sin entrelazamiento.
- **ZZFeatureMap**: interacciones $R_{ZZ}(x_i \cdot x_j)$ que capturan correlaciones de segundo orden (Havlíček et al., 2019).
- **PauliFeatureMap**: generaliza los anteriores con cadenas de Pauli arbitrarias.

El **ansatz RealAmplitudes** consiste en capas de rotaciones R_Y alternadas con puertas CNOT de entrelazamiento; el parámetro *reps* controla la profundidad. La Figura 1 muestra de forma esquemática la arquitectura del circuito cuántico previsto.




Figura 1: Esquema del circuito cuántico previsto: ZZFeature-Map (codificación angular + entrelazamiento lineal) seguido del *ansatz* RealAmplitudes (rotaciones R_Y parametrizadas + CNOT) y medición en la base computacional.

Los circuitos demasiado profundos pueden sufrir el fenómeno de *barren plateaus* (McClean et al., 2018; Larocca et al., 2025), es decir, regiones del espacio de parámetros donde los gradientes se desvanecen exponencialmente con el número de qubits. Además, los *kernels* cuánticos sufren un fenómeno análogo denominado **concentración exponencial**, donde los valores del *kernel* se vuelven indistinguibles entre sí al aumentar el número de qubits (Thanasilp et al., 2024).

4.3.5. Optimizadores

Los optimizadores clásicos más utilizados en el entrenamiento del VQC son: **COBYLA** (libre de gradiente, estable para simulaciones), **SPSA** (aproxima gradientes con perturbaciones estocásticas, robusto al ruido) y **L-BFGS-B** (quasi-Newton, requiere gradientes exactos) (Cerezo et al., 2021).

4.4. Estado del arte reciente (2024–2026)

Frente a los resultados optimistas iniciales, la literatura de los últimos años adopta una mirada más crítica sobre el QML. Bowles et al. (2024) realizan un *benchmark* a gran escala sobre 12 modelos cuánticos en 160 datasets y concluyen que los modelos clásicos *out-of-the-box* aún superan a los clasificadores cuánticos, e incluso que eliminar el entrelazamiento no degrada el desempeño. Schnabel et al. (2024) comparan sistemáticamente *Fidelity Quantum Kernels* (FQK) y *Projected Quantum Kernels* (PQK), mostrando que el *bandwidth* del *kernel* es decisivo para la generalización. En el plano teórico, Larocca et al. (2025) sintetizan la teoría unificada sobre *barren plateaus*, mientras que Thanasilp et al. (2024) formalizan la concentración exponencial en *kernels* cuánticos. Finalmente, Yu et al. (2025) ofrecen una revisión actualizada de algoritmos QML basados en circuitos variacionales, y Huang et al. (2021) establece criterios formales sobre cuándo los datos permiten esperar una ventaja cuántica real.

La literatura reciente, entonces, se enfoca menos en demostrar una ventaja cuántica universal y más en identificar las condiciones bajo las cuales los modelos cuánticos pueden ser competitivos.

4.5. Frameworks de QML

Cuadro 1: Comparativa de los principales *frameworks* de QML.

Framework	Empresa	Característica
Qiskit ML	IBM	API estable; HW IBM
PennyLane	Xanadu	Difer. automática
TF Quantum	Google	Integra TF + Cirq

En este proyecto se adopta **Qiskit Machine Learning** (Qiskit, 2024) como *framework* de referencia, por su integración con el ecosistema Qiskit y la disponibilidad de documentación oficial actualizada.

5. Metodología

5.1. Tipo de investigación

La investigación es de tipo **experimental y comparativa**. Se implementarán modelos cuánticos y clásicos bajo condiciones controladas, variando sistemáticamente los componentes del circuito cuántico y midiendo su efecto sobre métricas de desempeño estandarizadas. La Figura 2 resume el flujo de trabajo metodológico previsto, desde la adquisición de datos hasta el análisis comparativo final.

5.2. Investigación y diseño

Esta fase sienta las bases conceptuales y técnicas del proyecto y comprende tres actividades principales: la revisión bibliográfica, la selección del modelo cuántico y la elección del dataset.

5.2.1. Revisión sistemática (PRISMA)

Para sustentar la elección del modelo cuántico se realizó una revisión sistemática de la literatura siguiendo los lineamientos de la declaración **PRISMA** (*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*), con el fin de garantizar transparencia y reproducibilidad en el proceso de selección.

Estrategia de búsqueda. Se consultaron las bases de datos **IEEE Xplore**, **ScienceDirect**, **Nature**, **arXiv** y repositorios indexados en **Scopus**. La ventana temporal se restringió al periodo **2014–2026** para incluir tanto los trabajos fundacionales del QML como el estado del arte reciente. La cadena de búsqueda booleana principal fue:

("quantum machine learning" OR "QML" OR "VQC" OR "QSVM") AND ("classification" OR "benchmark") AND ("Qiskit" OR "NISQ" OR "variational")

Criterios de inclusión y exclusión.

- **Inclusión:** (i) trabajos que presenten formulación teórica o empírica de VQC, QSVC o QNN; (ii) estudios con *benchmarks* entre modelos cuánticos y clásicos sobre datasets de baja dimensionalidad; (iii) documentación oficial de *frameworks* (Qiskit ML).




Figura 2: Pipeline metodológico del proyecto. La rama cuántica (arriba) y la clásica (abajo) parten del mismo preprocesamiento, y sus predicciones convergen en una etapa de evaluación comparativa basada en métricas comunes.

- **Exclusión:** (i) artículos sin validación empírica ni aporte teórico claro; (ii) trabajos enfocados exclusivamente en criptografía o hardware físico; (iii) duplicados o versiones previas del mismo trabajo.

Proceso de selección. La Figura 3 resume el flujo PRISMA aplicado. De los 87 registros identificados inicialmente, tras eliminar duplicados, aplicar cribado por título y resumen, y realizar lectura completa, se seleccionaron **16 estudios finales** que conforman la base teórica y empírica de este proyecto.




Figura 3: Diagrama de flujo PRISMA aplicado a la revisión sistemática de la literatura.

Clasificación de los estudios incluidos. Los 16 estudios finales se agrupan en cuatro categorías según su aporte al proyecto (Tabla 2).

Cuadro 2: Distribución de los 16 estudios incluidos.

Categoría	n	Referencias
Fundacional QML	1	Biamonte et al. (2017)
Modelos	2	Havlíček et al. (2019); Rebentrost et al. (2014)
Teóricos/ prácticos	6	Cerezo et al. (2021); McClean et al. (2018); Larocca et al. (2025); Thanasisilp et al. (2024); Schuld et al. (2019); Preskill (2018)
Estado del arte 2024–26	4	Bowles et al. (2024); Schnabel et al. (2024); Yu et al. (2025); Huang et al. (2021)
Históricos/ recursos	3	Fisher (1936); Nielsen y Chuang (2010); Qiskit (2024)

Los hallazgos de la revisión permitieron concluir que, para problemas de clasificación de baja dimensionalidad como Iris, los modelos más adecuados en términos de viabilidad y madurez del ecosistema son el VQC y la QSVC, ambos implementables directamente en Qiskit

Machine Learning. Los *benchmarks* recientes (Bowles et al., 2024; Schnabel et al., 2024) indican además que las comparaciones contra *baselines* clásicos bien ajustados son indispensables para extraer conclusiones legítimas.

5.2.2. Selección del modelo cuántico

A partir de la revisión bibliográfica, se decidió trabajar con **dos familias de modelos complementarias**, una basada en optimización variacional y otra basada en *kernel*:

- **VQC** (variacional): combinación de un *feature map* ZZFeatureMap y un *ansatz* RealAmplitudes. Permite analizar el efecto de la profundidad del circuito y la elección del optimizador sobre el desempeño.
- **QSVC** (basado en *kernel*): FidelityQuantumKernel con ZZFeatureMap, delegando la optimización cuadrática al SVC de *scikit-learn*. Permite aprovechar la teoría consolidada de las SVM, sustituyendo únicamente la función de *kernel*.

Como modelos clásicos de referencia (*baseline*) se seleccionaron **SVM-RBF**, **MLP** y **KNN**, todos disponibles en *scikit-learn*. Las QNN se descartan en esta fase debido a su mayor complejidad de implementación y a la mayor sensibilidad a los *barren plateaus* reportada por McClean et al. (2018) y Larocca et al. (2025).

Cuadro 3: Modelos seleccionados para el proyecto.

Tipo	Modelo	Rol
Cuántico	VQC	Principal
Cuántico	QSVC	Complementario
Clásico	SVM-RBF	<i>Baseline</i>
Clásico	MLP	<i>Baseline</i>
Clásico	KNN	<i>Baseline</i>

La Figura 4 muestra, en estilo de diagrama de bloques UML, las diferencias arquitectónicas entre las dos familias de modelos cuánticos seleccionadas.

5.2.3. Elección del dataset

Siguiendo el criterio de equilibrio entre representatividad y viabilidad de codificación en pocos qubits, se seleccionaron:

- **Dataset Iris** (Fisher, 1936): 150 muestras, 4 características (longitud y ancho de sépalo y pétalo) y 3 clases (*setosa*, *versicolor*, *virginica*) con 50 muestras cada una. Es el conjunto de referencia *de facto* en estudios introductorios de QML (Havlíček et al., 2019),




Figura 4: Comparativa arquitectónica VQC (arriba) vs QSVC (abajo). El VQC entrena parámetros internos del circuito mediante un bucle de optimización clásico (línea punteada); la QSVC solo emplea el circuito para calcular un *kernel* y delega la optimización al SVC clásico.

ya que sus 4 características se ajustan de manera natural a una codificación angular en 4 qubits y permite comparar resultados con la literatura.

- **Dataset MNIST reducido** (*digits* de *scikit-learn*): se filtrará a las clases 0 y 1 (aproximadamente 360 muestras) y se aplicará PCA para reducir las 64 características originales a 4 componentes, manteniendo la compatibilidad con 4 qubits. Se utilizará como conjunto complementario para evaluar la generalización del modelo a un problema de naturaleza distinta.

En ambos casos, las características se normalizarán al rango $[0, \pi]$ para su codificación angular en las puertas de rotación cuánticas, siguiendo la práctica habitual en la literatura (Schuld et al., 2019; Havlíček et al., 2019).

Producto esperado. Un diseño preliminar que especifique: (i) los modelos cuánticos y clásicos a implementar, (ii) los datasets y su pre-procesamiento, y (iii) los *feature maps* y *ansatz* a explorar. Sobre esta base se desarrollarán las fases subsiguientes de implementación, experimentación y análisis comparativo.

Referencias

- Biamonte, J., Wittek, P., Pancotti, N., Rebentrost, P., Wiebe, N. y Lloyd, S. (2017). *Quantum machine learning*. Nature, 549(7671), 195–202.
- Bowles, J., Ahmed, S. y Schuld, M. (2024). *Better than classical? The subtle art of benchmarking quantum machine learning models*. arXiv:2403.07059.
- Cerezo, M., Arrasmith, A., Babbush, R., et al. (2021). *Variational quantum algorithms*. Nature Reviews Physics, 3, 625–644.
- Fisher, R. A. (1936). *The use of multiple measurements in taxonomic problems*. Annals of Eugenics, 7(2), 179–188.
- Havlíček, V., Córcoles, A. D., Temme, K., et al. (2019). *Supervised learning with quantum-enhanced feature spaces*. Nature, 567, 209–212.
- Huang, H.-Y., Broughton, M., Mohseni, M., et al. (2021). *Power of data in quantum machine learning*. Nature Communications, 12, 2631.
- Larocca, M., Thanasilp, S., Wang, S., et al. (2025). *Barren plateaus in variational quantum computing*. Nature Reviews Physics.
- McClean, J. R., Boixo, S., Smelyanskiy, V. N., Babbush, R. y Neven, H. (2018). *Barren plateaus in quantum neural network training landscapes*. Nature Communications, 9, 4812.
- Nielsen, M. A. y Chuang, I. L. (2010). *Quantum Computation and Quantum Information*. 10th Anniversary Edition. Cambridge University Press.
- Preskill, J. (2018). *Quantum computing in the NISQ era and beyond*. Quantum, 2, 79.
- Qiskit Contributors. (2024). *Qiskit Machine Learning Documentation*. <https://qiskit-community.github.io/qiskit-machine-learning/>
- Rebentrost, P., Mohseni, M. y Lloyd, S. (2014). *Quantum support vector machine for big data classification*. Physical Review Letters, 113, 130503.
- Schnabel, J., Kreplin, D. A., Roth, M., et al. (2024). *Quantum kernel methods under scrutiny: a benchmarking study*. Quantum Machine Intelligence, 7, 58. arXiv:2409.04406.
- Schuld, M., Bergholm, V., Gogolin, C., Izaac, J. y Killoren, N. (2019). *Evaluating analytic gradients on quantum hardware*. Physical Review A, 99, 032331.
- Thanasilp, S., Wang, S., Cerezo, M. y Holmes, Z. (2024). *Exponential concentration in quantum kernel methods*. Nature Communications, 15, 5200.
- Yu, R., Zhang, X. y Ren, S. (2025). *A review of quantum machine learning algorithms based on variational quantum circuit*. Journal of Computer Research and Development, 62(4), 821–851.