



Clasificación Cuántica sobre Hardware Real de IBM: Impacto del Ruido NISQ y Limitaciones de Muestreo

Edmil Jampier Saire Bustamante (174449)

Medaly Lozano Llacctahuaman (195040)

José Francisco Puma Potosino (164248)

Resumen. El presente estudio expande la evaluación de clasificadores cuánticos transicionando de entornos simulados hacia procesadores cuánticos reales (IBM Heron r2) de la etapa NISQ. Se evaluó el desempeño de Modelos Cuánticos Variacionales (VQC) optimizados y Máquinas de Vectores de Soporte Cuánticas (QSVC) frente a conjuntos de datos (Iris y MNIST) severamente restringidos a 15 muestras para ajustarse a las limitaciones computacionales de la plataforma IBM Quantum. Se evidenció empíricamente que la reducción muestral provoca un colapso en la capacidad de generalización del kernel cuántico (40 % de accuracy tanto en simulador como en hardware real), indicando que el cuello de botella predominante no es la decoherencia cuántica, sino la carencia de densidad topológica de los datos. Así mismo, métodos de mitigación de errores de lectura (TREX) resultaron inefectivos ante tan aguda varianza estadística.

Palabras clave: Hardware Cuántico, IBM Quantum, QML, Ruido NISQ, TREX, VQC, QSVC, Limitación Muestral.

1. Introducción

Durante la etapa computacional conocida como *Noisy Intermediate-Scale Quantum* (NISQ), los algoritmos híbridos y de aprendizaje automático cuántico (QML) emergen como candidatos principales para alcanzar ventaja cuántica. Sin embargo, su ejecución práctica está invariablemente condicionada por la decoherencia intrínseca y el ruido operacional de los procesadores actuales (Preskill, 2018).

En la primera fase de este proyecto, se exploró empíricamente el rendimiento de un Clasificador Cuántico Variacional (VQC) (Cerezo et al., 2021) y una Máquina de Vectores de Soporte Cuántica (QSVC) (Havlíček et al., 2019) utilizando un simulador ideal (*Statevector Simulator*). Los resultados demostraron que la QSVC poseía una ventaja matemática teórica respecto al VQC sub-entrenado, pero aún cedía frente a la eficiencia empírica de los clásicos algoritmos SVM-RBF y Redes Neuronales.

La presente **Segunda Parte** del estudio persigue un doble objetivo: en primer lugar, subsanar la convergencia defectuosa observada en el VQC mediante la dilatación del índice de optimización. En segundo y principal lugar, migrar la ejecución de la generación del Kernel

Cuántico desde un entorno libre de ruido hacia procesadores físicos de la plataforma IBM Quantum (familia *Heron r2*).

La pregunta de investigación rectora de esta fase experimenta no sólo busca medir el grado de *degradación* que sufre la métrica de exactitud (Accuracy) ante el ruido de hardware, sino también evaluar la verdadera aplicabilidad de técnicas algorítmicas diseñadas para la supresión de errores, específicamente la mitigación local de errores de medición de qubits (TREX), sobre conjuntos de datos fuertemente limitados por cuotas operacionales.

2. Marco Teórico

Para contextualizar el impacto de las variaciones operativas durante la experimentación en QPU, se fundamentan teóricamente los métodos de evaluación del error de la plataforma.

2.1. Procesadores IBM Heron r2

La topología implementada por IBM en sus procesadores de escala de utilidad (156 qubits), como el backend `ibm_vez`, se fundamenta en un esquema de acoplamiento hexagonal que reduce la interferencia de canal

(*cross-talk*). A pesar de estos avances de ingeniería de microondas, la interacción de las compuertas CX aún está limitada por errores del orden de 10^{-3} , lo que causa la atenuación asimétrica de amplitudes (IBM Quantum, 2023).

2.2. Fidelidad del Estado de Bell

El estado de superposición entrelazada $|\Phi^+\rangle = \frac{1}{\sqrt{2}}(|00\rangle + |11\rangle)$ se posiciona como el patrón métrico por excelencia en la validación del hardware cuántico. Idealmente, la medición reiterativa de este estado converge a una distribución uniforme discreta de $P(00) = 0,5$ y $P(11) = 0,5$. La variación estadística obtenida experimentalmente frente a la distribución teórica provee un indicador directo y verificable del volumen del ruido combinado de preparación, compuerta CX y medición (*SPAM errors*).

2.3. Mitigación de Errores de Medición (TREX)

La técnica *Twirled Readout Error Extinction* (TREX) se basa en la aplicación aleatoria de compuertas Pauli-X inmediatamente previas a las mediciones, seguido de un post-procesamiento clásico para deshacer lógicamente el efecto de estas transformaciones. Esta estrategia algorítmica traslada el asimétrico ruido de medición a un canal de depolarización local, permitiendo recuperar por vías invertidas los valores de expectación originales sin la necesidad de escalar la profundidad del circuito principal.

3. Metodología y Restricciones Operativas

Dada la transición de la simulación en procesadores locales hacia el cómputo físico a través de la nube de IBM Quantum, se requirió implementar una metodología sumamente ajustada a las políticas de uso (Open Plan, 10 minutos de QPU por mes calendario).

3.1. Estandarización del Dataset

El análisis utilizó el conjunto tabular Iris y un subconjunto numérico binario (dígitos 0 y 1) del conjunto MNIST. Ambos datasets sufrieron transformaciones algorítmicas intensivas:

1. **Normalización de ngulos:** Escalamiento de valores físicos al dominio $x \in [0, \pi]$ para inyección de parámetros en rotores Pauli-Z y Pauli-Y del *ZZFeatureMap*.
2. **Reducción de Dimensionalidad Extrema:** Con el propósito de incrustar vectores de imagen (MNIST) en un registro de 4 qubits, se ejecutó un PCA clásico reteniendo únicamente las 4 componentes principales de mayor varianza.

3.2. Dimensionamiento Muestral (Subset Hardware)

La evaluación de un Kernel de Fidelidad Cuántica implica la construcción y envío transpilado de matrices de circuitos cuyo costo crece exponencialmente con el tamaño muestral ($O(n^2)$). Ante el techo duro de tiempo QPU, el diseño del experimento forzó el particionamiento aleatorio (*random seed = 42*) en subconjuntos de evaluación miniaturizados: **10 vectores de entrenamiento y 5 vectores de prueba por corrida**.

3.3. Parámetros Cuánticos y QPU

Toda invocación algorítmica al hardware delegó a la primitiva `SamplerV2` en el backend `ibm_fez` (156 qubits Heron). El optimizador seleccionado para asegurar la convergencia del vector variacional en la prueba local (*Baseline VQC*) fue *COBYLA*, incrementando su profundidad de búsqueda de 200 a 300 iteraciones (respecto a la Parte 1). Las evaluaciones de expectación utilizaron 2048 *shots* por distribución de probabilidad para equilibrar resolución matemática y tiempo de ejecución asíncrona.

4. Resultados

4.1. Modelo Variacional Corregido

Como se evidencia en la Figura 1, el modelo Variacional VQC ajustado (300 iteraciones COBYLA, 3 semillas iniciales) logró un promedio de 50.37 % de precisión sobre el conjunto Iris, escalando a un máximo de 57.78 %. Este comportamiento demuestra que la deficiencia algorítmica se encontraba en una interrupción temprana de la función de costo (*loss landscape*).




Figura 1: Métricas de exactitud del VQC mejorado y la frontera límite clásica (SVM 93.3 %).

4.2. Verificación Geométrica del Ruido (Bell)

La inicialización simétrica del circuito de prueba para el estado máximamente entrelazado $|\Phi^+\rangle$ sobre `ibm_fez` arrojó histogramas de probabilidad distorsionados frente al vector de simulación (Figura 2). Las amplitudes pérdidas sobre los componentes $|00\rangle$ y $|11\rangle$ actúan como traza de decoherencia geométrica del hardware (*leakage* y errores T_1).




Figura 2: Comparación de distribuciones de probabilidad entre *Statevector* e *ibm_fez* para el estado de Bell.

4.3. Kernel QSVC: Evaluación de Dimensionalidad

La Figura 3 reporta el clímax experimental: la matriz de Kernel Cuántico construida bajo simulador vs. hardware, aplicadas a un microscópico subconjunto de 10 variables continuas. Ambas ejecuciones arrojaron un idéntico colapso técnico: **40.00 % de accuracy**.




Figura 3: Matrices de similitud subyacentes del Kernel y su rendimiento estancado (40.0%) en hardware y simulación bajo limitación estricta de muestra.

4.4. Mitigación TREX y Métricas de Imagen

La implementación activa de la mitigación local (Figura 4) mantuvo invariable el factor de predicción (40.0%). Adicionalmente, el rendimiento cruzado del modelo sobre tensores de imagen MNIST comprimidos (Figura 5) fue analizado asincrónicamente y consolidado estadísticamente.




Figura 4: Gráfico de estabilidad de predicción post-procesamiento TREX.




Figura 5: Desempeño comparativo de clasificación binaria para el dataset *digits* super-reducido (PCA a 4D).

Finalmente, la visión panorámica de los métodos QML evaluados queda recopilada transversalmente mediante el espectro radial (Figura 6).



Figura 6: Radar de Rendimiento de Precisión y Estabilidad F1 (Macro) para los 5 escenarios probados.

5. Discusión Teórica y Conclusiones del Análisis Experimental

El pilar analítico fundamental derivado de la experimentación directa en la QPU de IBM radica en la interpretación del fenómeno de estancamiento métrico (40.0% *accuracy*) reflejado fidedignamente tanto en el simulador cuántico aislado de ruido como en el *backend ibm_fez*.

Este comportamiento isofórmico demuestra que la limitación del hardware ruidoso no jugó un rol estadístico dominante en la degeneración del modelo. Muy por el contrario, fue la **drástica limitación del subconjunto de entrenamiento** (10 muestras frente a un total de 150 para la distribución canónica Iris) lo que destruyó la geometría interna del clasificador SVM acoplado al kernel cuántico (Schuld and Killoran, 2019). Un clasificador lineal (SVM) empotrado en un espacio de Hilbert superior no tiene la densidad topológica requerida para señalar fronteras de decisión generalizables si no posee suficientes vectores de soporte para asentar el margen matemático.

Consecuencia directa de esta parálisis métrica fue la nulidad práctica del algoritmo de corrección **TREX**. Las sub-rutinas matemáticas de esta tecnología de mitigación de lectura están diseñadas para limpiar las distribuciones finas de la medición física; pero una medición física corregida de un kernel *geoméricamente nulo* seguirá prediciendo *outliers* a un ritmo estancado, tal como se comprobó en los resultados tabulados.

Respecto al colapso de la red cuántica frente al análisis multivariante (**MNIST**), este hallazgo solidifica empíricamente que las sub-rutinas de compresión visual agresiva (Principal Component Analysis limitado a 4 valores atómicos) filtran la médula frecuencial de una matriz gráfica. Aunque un modelo SVM clásico reportó artificialmente un 100% (producto natural de un sobreajuste grosero de pocas variables en una arquitectura lineal sobre parametrizada), los feature maps cuánticos como *ZZFeatureMap* requieren distribuciones paramétricas que eviten regiones rígidas donde la amplitud variacional decae.

6. Conclusiones y Trabajo Futuro

Este proyecto validó la integración completa entre el stack químico-computacional *Qiskit* y un modelo métrico cuántico operado físicamente en un procesador de IBM. A modo de síntesis:

- **Verificación Variacional:** Se estandarizó que los modelos de Ansatz lineal exigen, como mínimo matemático, trescientas iteraciones de evaluación de costo COBYLA para escapar de mínimos locales tempranos en tareas QML.
- **La Carencia del NISQ de Cuota:** El procesamiento cuántico de nube gratis (Open Plan) ahoga la expresividad real de cualquier red de máquina. La decisión de muestreo restrictiva en hardware expuso una asimetría estadística donde las variables dependientes fallaron por *Underfitting* Muestral más que por ruido topológico.

Proyecciones a Futuro

La investigación requiere abandonar la experimentación híbrida trivial y migrar a recursos físicos asignados (Premium Access Programs) que habiliten la inyección continua de la totalidad de datos en el Kernel físico. Bajo tal prerrogativa, el uso de las técnicas V2 nativas (*EstimatorV2*) junto a métodos de supresión de

ruido algorítmico puro como **ZNE** (Zero Noise Extrapolation) podrían proveer, por primera vez, un campo de evaluación parejo donde medir fehacientemente la latencia frente al modelo clásico Multicapa Perceptrón (MLP) (Larocca et al., 2025; Biamonte et al., 2017).

Referencias

- Biamonte, J., Wittek, P., Pancotti, N., Rebentrost, P., Wiebe, N., and Lloyd, S. (2017). Quantum machine learning. *Nature*, 549(7671):195–202.
- Cerezo, M., Arrasmith, A., Babbush, R., Benjamin, S. C., Endo, S., Fujii, K., McClean, J. R., Mitarai, K., Yuan, X., Cincio, L., and Coles, P. J. (2021). Variational quantum algorithms. *Nature Reviews Physics*, 3(9):625–644.
- Havlíček, V., Córcoles, A. D., Temme, K., Harrow, A. W., Kandala, A., Chow, J. M., and Gambetta, J. M. (2019). Supervised learning with quantum-enhanced feature spaces. *Nature*, 567(7747):209–212.
- IBM Quantum (2023). Ibm quantum computing. <https://quantum-computing.ibm.com/>.
- Larocca, M., Thanasilp, S., Wang, S., Beckey, J. L., et al. (2025). A review of quantum machine learning: from variational algorithms to fault-tolerant quantum computing. *Nature Reviews Physics*.
- Preskill, J. (2018). Quantum computing in the nisq era and beyond. *Quantum*, 2:79.
- Schuld, M. and Killoran, N. (2019). Quantum machine learning in feature hilbert spaces. *Physical Review Letters*, 122(4):040504.