



Clasificación Cuántica sobre Hardware Real de IBM: Impacto del Ruido NISQ y Limitaciones de Muestreo

Edmil Jampier Saire Bustamante (174449)

Medaly Lozano Llacctahuaman (195040)

José Francisco Puma Potosino (164248)

Resumen. El presente estudio expande la evaluación de clasificadores cuánticos transicionando de entornos simulados hacia procesadores cuánticos reales (IBM Heron r2) de la etapa NISQ. Se evaluó el desempeño de Modelos Cuánticos Variacionales (VQC) optimizados y Máquinas de Vectores de Soporte Cuánticas (QSVC) frente a conjuntos de datos (Iris y MNIST) severamente restringidos a 22 muestras (13 entrenamiento / 9 prueba) para ajustarse a las limitaciones computacionales de la plataforma IBM Quantum. Se evidenció empíricamente que la combinación de escasez muestral y ruido de hardware provoca un colapso diferenciado en la capacidad de generalización del kernel cuántico: la QSVC sobre el subset reducido obtuvo 33.33 % de accuracy en simulador ideal frente a tan solo 11.11 % en hardware real (`ibm_fez`), revelando que el ruido NISQ degrada significativamente el rendimiento incluso sobre un kernel ya debilitado por la insuficiencia de datos. Asimismo, métodos de mitigación de errores de lectura (TREX) resultaron inefectivos ante tan severa degradación combinada. En contraste, la clasificación binaria MNIST mostró un comportamiento atípico, con el hardware (88.89 %) superando al simulador (77.78 %), efecto atribuible a la naturaleza estocástica del muestreo cuántico en problemas de baja dimensionalidad.

Palabras clave: Hardware Cuántico, IBM Quantum, QML, Ruido NISQ, TREX, VQC, QSVC, Limitación Muestral.

1. Introducción

Durante la etapa computacional conocida como *Noisy Intermediate-Scale Quantum* (NISQ), los algoritmos híbridos y de aprendizaje automático cuántico (QML) emergen como candidatos principales para alcanzar ventaja cuántica. Sin embargo, su ejecución práctica está invariablemente condicionada por la decoherencia intrínseca y el ruido operacional de los procesadores actuales (Preskill, 2018).

En la primera fase de este proyecto, se exploró empíricamente el rendimiento de un Clasificador Cuántico Variacional (VQC) (Cerezo et al., 2021) y una Máquina de Vectores de Soporte Cuántica (QSVC) (Havlíček et al., 2019) utilizando un simulador ideal (*Statevector Simulator*). Los resultados demostraron que la QSVC poseía una ventaja matemática teórica respecto al VQC sub-entrenado, pero aún cedía frente a la eficiencia empírica de los clásicos algoritmos SVM-RBF y Redes Neuronales.

La presente **Segunda Parte** del estudio persigue un doble objetivo: en primer lugar, subsanar la convergen-

cia defectuosa observada en el VQC mediante la dilatación del índice de optimización. En segundo y principal lugar, migrar la ejecución de la generación del Kernel Cuántico desde un entorno libre de ruido hacia procesadores físicos de la plataforma IBM Quantum (familia *Heron r2*).

La pregunta de investigación rectora de esta fase experimenta no sólo busca medir el grado de *degradación* que sufre la métrica de exactitud (Accuracy) ante el ruido de hardware, sino también evaluar la verdadera aplicabilidad de técnicas algorítmicas diseñadas para la supresión de errores, específicamente la mitigación local de errores de medición de qubits (TREX), sobre conjuntos de datos fuertemente limitados por cuotas operacionales. El código fuente integral de este proyecto y los cuadernos de experimentación están documentados públicamente en el repositorio: https://github.com/milith0kun/Computacion_Cuantica.

2. Marco Teórico

Para contextualizar el impacto de las variaciones operativas durante la experimentación en QPU, se fundamentan teóricamente los métodos de evaluación del error de la plataforma.

2.1. Computación cuántica

2.1.1. Qubits y estados cuánticos

El qubit es la unidad fundamental de información cuántica (Nielsen and Chuang, 2010). A diferencia del bit clásico, puede existir en una superposición de los estados $|0\rangle$ y $|1\rangle$:

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle, \quad |\alpha|^2 + |\beta|^2 = 1, \quad (1)$$

donde $\alpha, \beta \in \mathbb{C}$ son amplitudes de probabilidad. Un sistema de n qubits vive en un espacio de Hilbert de dimensión 2^n , propiedad que constituye la base del potencial computacional cuántico.

2.1.2. Puertas cuánticas

Las puertas cuánticas son operaciones unitarias que transforman el estado de los qubits. Las puertas de rotación $R_Y(\theta)$ y $R_Z(\theta)$ son particularmente relevantes para la codificación angular de datos:

$$R_Y(\theta) = \begin{bmatrix} \cos \frac{\theta}{2} & -\sin \frac{\theta}{2} \\ \sin \frac{\theta}{2} & \cos \frac{\theta}{2} \end{bmatrix}. \quad (2)$$

Las puertas CNOT generan *entrelazamiento* entre qubits, recurso esencial para capturar correlaciones no triviales en los datos (Nielsen and Chuang, 2010).

2.1.3. Circuitos parametrizados, medición y QFT

Un circuito parametrizado $U(\mathbf{x}, \boldsymbol{\theta})$ se compone de un *feature map* $U_\phi(\mathbf{x})$ —que codifica datos clásicos en estados cuánticos— y un *ansatz* $U_W(\boldsymbol{\theta})$ con parámetros entrenables. La **medición** proyecta el estado cuántico sobre la base computacional con probabilidades $|\langle z|\psi\rangle|^2$. La **transformada cuántica de Fourier** (QFT) es un bloque fundamental empleado en algoritmos como Shor y en estimación de fase, y subyace en algunos esquemas de codificación de datos (Nielsen and Chuang, 2010).

2.2. Machine Learning clásico

2.2.1. Aprendizaje supervisado y no supervisado

El aprendizaje supervisado busca aproximar una función $f: \mathcal{X} \rightarrow \mathcal{Y}$ a partir de pares (x_i, y_i) e incluye tareas de *clasificación* y *regresión*. El aprendizaje no supervisado, en cambio, abarca tareas como *clustering* y reducción de dimensionalidad cuando las etiquetas no están disponibles.

2.2.2. SVM, MLP, KNN y métricas

La SVM busca el hiperplano que maximiza el margen entre clases. Con el *kernel* RBF

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2), \quad (3)$$

la SVM puede clasificar datos no linealmente separables, lo que la convierte en un *baseline* natural para comparar con la QSVC. El Perceptrón Multicapa

(MLP) aprende funciones no lineales mediante capas ocultas, mientras que KNN clasifica según la clase mayoritaria de los k vecinos más cercanos. La evaluación se realiza comúnmente con *accuracy*, *precision*, *recall*, *F1-score* y matriz de confusión.

2.3. Quantum Machine Learning (QML)

2.3.1. Variational Quantum Classifier (VQC)

El VQC (Havlíček et al., 2019) utiliza un circuito parametrizado entrenado de forma híbrida cuántico-clásica. La función de costo típicamente empleada es la entropía cruzada:

$$\mathcal{L}(\boldsymbol{\theta}) = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{ic} \log(\hat{y}_{ic}(\boldsymbol{\theta})), \quad (4)$$

donde los parámetros $\boldsymbol{\theta}$ se optimizan mediante un optimizador clásico, mientras que la evaluación del circuito $U(\mathbf{x}, \boldsymbol{\theta})$ se realiza en el dispositivo cuántico.

2.3.2. Quantum SVM (QSVC)

La QSVC (Rebentrost et al., 2014; Havlíček et al., 2019) sustituye el *kernel* clásico por un *kernel* cuántico de fidelidad:

$$K_Q(\mathbf{x}_i, \mathbf{x}_j) = |\langle \phi(\mathbf{x}_j) | \phi(\mathbf{x}_i) \rangle|^2, \quad (5)$$

donde $|\phi(\mathbf{x})\rangle = U_\phi(\mathbf{x})|0\rangle^{\otimes n}$. La idea es que el *feature map* cuántico mapee los datos a un espacio de Hilbert de alta dimensionalidad que, eventualmente, podría ser difícil de simular clásicamente (Schuld and Killoran, 2019).

2.3.3. Quantum Neural Networks (QNN)

Las QNN extienden la idea del VQC a arquitecturas tipo red neuronal, donde las “neuronas” se realizan mediante circuitos cuánticos parametrizados, entrenadas con la regla de *parameter-shift* (Schuld and Killoran, 2019) y *back-propagation* clásica para los parámetros del modelo (Yu et al., 2025).

2.3.4. Feature maps y ansatz

Los principales *feature maps* considerados son:

- **ZFeatureMap**: rotaciones $R_Z(x_i)$ sin entrelazamiento.
- **ZZFeatureMap**: interacciones $R_{ZZ}(x_i \cdot x_j)$ que capturan correlaciones de segundo orden (Havlíček et al., 2019).
- **PauliFeatureMap**: generaliza los anteriores con cadenas de Pauli arbitrarias.

El *ansatz* **RealAmplitudes** consiste en capas de rotaciones R_Y alternadas con puertas CNOT de entrelazamiento; el parámetro *reps* controla la profundidad. La Figura 1 muestra de forma esquemática la arquitectura del circuito cuántico previsto.




Figura 1: Esquema del circuito cuántico previsto: ZZFeatureMap (codificación angular + entrelazamiento lineal) seguido del *ansatz* RealAmplitudes (rotaciones R_Y parametrizadas + CNOT) y medición en la base computacional.

Las Figuras 2–3 muestran los circuitos reales generados por Qiskit, descompuestos en puertas básicas.




Figura 2: ZZFeatureMap descompuesto en puertas básicas (H, P, CX). Se observan las rotaciones de fase $P(2x_i)$ que codifican cada *feature* y las interacciones ZZ implementadas mediante pares CNOT-P-CNOT entre qubits vecinos (entrelazamiento lineal, 2 repeticiones).




Figura 3: Circuito VQC completo: ZZFeatureMap (codificación de datos) + barrera + RealAmplitudes (16 parámetros entrenables θ) + medición. El flujo es: $|0000\rangle \rightarrow U_\phi(\mathbf{x}) \rightarrow U_W(\theta) \rightarrow$ Medición.




Figura 4: ZZFeatureMap con datos reales del dataset Iris inyectados: cada valor numérico ($x_0=0,70$, $x_1=0,65$, $x_2=1,06$, $x_3=1,31$ rad) se convierte en un ángulo de rotación de fase en las compuertas del circuito cuántico.

Los circuitos demasiado profundos pueden sufrir el fenómeno de *barren plateaus* (McClean et al., 2018; Larocca et al., 2025), es decir, regiones del espacio de parámetros donde los gradientes se desvanecen exponencialmente con el número de qubits. Además, los *kernels* cuánticos sufren un fenómeno análogo denominado **concentración exponencial**, donde los valores del *kernel* se vuelven indistinguibles entre sí al aumentar el número de qubits (Thanasilp et al., 2024).

2.3.5. Optimizadores

Los optimizadores clásicos más utilizados en el entrenamiento del VQC son: **COBYLA** (libre de gradiente, estable para simulaciones), **SPSA** (aproxima gradientes con perturbaciones estocásticas, robusto al ruido) y **L-BFGS-B** (quasi-Newton, requiere gradientes exactos) (Cerezo et al., 2021).

2.4. Estado del arte reciente (2024–2026)

Frente a los resultados optimistas iniciales, la literatura de los últimos años adopta una mirada más crítica sobre el QML. Bowles et al. (2024) realizan un *benchmark* a gran escala sobre 12 modelos cuánticos en 160 datasets y concluyen que los modelos clásicos *out-of-the-box* aún superan a los clasificadores cuánticos, e incluso que eliminar el entrelazamiento no degrada el desempeño. Schnabel et al. (2024) comparan sistemáticamente *Fidelity Quantum Kernels* (FQK) y *Projected Quantum Kernels* (PQK), mostrando que el *bandwidth* del *kernel* es decisivo para la generalización. En el plano teórico, Larocca et al. (2025) sintetizan la teoría unificada sobre *barren plateaus*, mientras que Thanasilp et al. (2024) formalizan la concentración exponencial en *kernels* cuánticos. Finalmente, Yu et al. (2025) ofrecen una revisión actualizada de algoritmos QML basados en circuitos variacionales, y Huang et al. (2021) establece criterios formales sobre cuándo los datos permiten esperar una ventaja cuántica real.

La literatura reciente, entonces, se enfoca menos en demostrar una ventaja cuántica universal y más en identificar las condiciones bajo las cuales los modelos cuánticos pueden ser competitivos.

2.5. Frameworks de QML

Cuadro 1: Comparativa de los principales *frameworks* de QML.

Framework	Empresa	Característica
Qiskit ML	IBM	API estable; HW IBM
PennyLane	Xanadu	Difer. automática
TF Quantum	Google	Integra TF + Cirq

En este proyecto se adopta **Qiskit Machine Learning** (Qiskit Community, 2024) como *framework* de referencia, por su integración con el ecosistema Qiskit y la disponibilidad de documentación oficial actualizada.

2.6. Procesadores IBM Heron r2

La topología implementada por IBM en sus procesadores de escala de utilidad (156 qubits), como el backend `ibm_fez`, se fundamenta en un esquema de acoplamiento hexagonal que reduce la interferencia de canal (*cross-talk*). A pesar de estos avances de ingeniería de microondas, la interacción de las compuertas CX aún está limitada por errores del orden de 10^{-3} , lo que causa la atenuación asimétrica de amplitudes (IBM Quantum, 2023).

2.7. Fidelidad del Estado de Bell

El estado de superposición entrelazada $|\Phi^+\rangle = \frac{1}{\sqrt{2}}(|00\rangle + |11\rangle)$ se posiciona como el patrón métrico por excelencia en la validación del hardware cuántico. Idealmente, la medición reiterativa de este estado converge a una distribución uniforme discreta de $P(00) = 0,5$ y $P(11) = 0,5$. La variación estadística obtenida experimentalmente frente a la distribución teórica provee un indicador directo y verificable del volumen del ruido combinado de preparación, compuerta CX y medición (*SPAM errors*).

2.8. Mitigación de Errores de Medición (TREX)

La técnica *Twirled Readout Error Extinction* (TREX) se basa en la aplicación aleatoria de compuertas Pauli-X inmediatamente previas a las mediciones, seguido de un post-procesamiento clásico para deshacer lógicamente el efecto de estas transformaciones. Esta estrategia algorítmica traslada el asimétrico ruido de medición a un canal de depolarización local, permitiendo recuperar por vías invertidas los valores de expectación originales sin la necesidad de escalar la profundidad del circuito principal.

3. Experimentación

3.1. Introducción a la experimentación

La presente sección describe el proceso metodológico seguido para la validación de los modelos de aprendizaje automático cuántico (QML) desarrollados en esta investigación. Se detallan los elementos necesarios para la ejecución de los experimentos, incluyendo el entorno de trabajo híbrido (simulación local y hardware cuántico en la nube), los conjuntos de datos utilizados, el diseño experimental y la implementación del sistema. El objetivo principal es garantizar la reproducibilidad del estudio y establecer un marco claro para evaluar el impacto del ruido NISQ y las limitaciones de muestreo en el hardware de IBM.

3.2. Entorno experimental

El entorno experimental comprende recursos de hardware y software distribuidos, abarcando cómputo clásico local y procesamiento cuántico remoto.

3.2.1. Hardware

Se utilizaron dos entornos de hardware diferenciados:

- **Cómputo Clásico (Simulación):** Estación de trabajo local utilizada para la orquestación, preprocesamiento y ejecución del simulador *Statevector*.
 - **Procesador (CPU):** AMD Ryzen 7 9700X 8-Core Processor.
 - **Memoria RAM:** 32 GB.
 - **Unidad de almacenamiento:** 1 TB SSD NVMe (Kingston).
 - **Unidad de procesamiento gráfico (GPU):** NVIDIA GeForce GTX 1050 Ti (4GB VRAM).

- **Cómputo Cuántico (Hardware Real):** Procesador cuántico *ibm_fez* de IBM Quantum.

- **Arquitectura:** IBM Heron r2.
- **Capacidad:** 156 qubits físicos.
- **Topología:** Acoplamiento hexagonal pesado enfocado en reducción de *cross-talk*.

3.2.2. Software

Las herramientas y tecnologías empleadas fueron:

- **Lenguaje de programación:** Python 3.10+.
- **Frameworks y librerías:** Qiskit, Qiskit Machine Learning, Qiskit IBM Runtime, Scikit-learn, Matplotlib, Numpy.
- **Entorno de desarrollo (IDE):** Jupyter Notebooks y Google Colab.
- **Sistema operativo:** Entorno agnóstico de ejecución web.

3.3. Datos utilizados

Se utilizaron dos conjuntos de datos canónicos de complejidad distinta para evaluar la capacidad de generalización de los modelos.

3.3.1. Origen de los datos

Los datos provienen de repositorios públicos integrados en *scikit-learn*:

- **Dataset públicos:** Conjunto de datos *Iris* y subconjunto del dataset *MNIST*.

3.3.2. Descripción del conjunto de datos

- **Iris Dataset:** 150 registros, 4 variables numéricas continuas (longitud y ancho de sépalo y pétalo), y 3 clases balanceadas.
- **MNIST Dataset (reducido):** Subconjunto binario filtrado a las clases '0' y '1', con 64 atributos numéricos originales (píxeles 8x8).

3.3.3. Preprocesamiento de datos

Antes de la inyección cuántica, los datos fueron sometidos a las siguientes transformaciones:

- **Limpieza de datos:** Verificación de integridad y ausencia de valores nulos.
- **Reducción de Dimensionalidad:** Aplicación de Análisis de Componentes Principales (PCA) a MNIST para comprimir a 4 dimensiones compatibles con un registro de 4 qubits.
- **Normalización:** Escalamiento Min-Max para confinar todas las características al intervalo $x \in [0, \pi]$, habilitando la codificación angular (*Angle Embedding*).
- **División de conjuntos:** Separación en conjuntos de entrenamiento (70%) y prueba (30%). En el hardware real, la muestra se redujo drásticamente a 13 muestras de entrenamiento y 9 de prueba debido a restricciones de cuota computacional, lo que implica una resolución de accuracy de $\pm 11.1\%$ por muestra de test.

3.4. Diseño experimental

Define la estratificación de las pruebas para evaluar la propuesta.

3.4.1. Objetivo experimental

El objetivo es cuantificar la degradación de exactitud (Accuracy) que sufren VQC y QSVC al transicionar de un simulador perfecto a un procesador ruidoso, identificando el impacto simultáneo de la escasez de datos muestrales dictada por el entorno de nube gratuita.

3.4.2. Métricas de evaluación

Se emplean las siguientes métricas:

- **Exactitud (Accuracy):** Proporción global de predicciones correctas.
- **Precisión, Recall y F1-Score:** Evaluación desglosada por clase.
- **Matriz de Confusión:** Visualización de falsos positivos y negativos.
- **Tiempo de Ejecución (QPU):** Costo temporal de la invocación al hardware.

3.4.3. Escenarios de prueba

Se definieron tres escenarios progresivos:

- **Escenario 1 (Simulación Ideal):** Evaluación de VQC, QSVC y modelos clásicos (SVM-RBF) en `StatevectorSimulator` sin ruido.
- **Escenario 2 (Hardware Real sin Mitigación):** Ejecución de la matriz del Kernel en `ibm_vez` bajo decoherencia natural y muestreo minúsculo.
- **Escenario 3 (Hardware Real con Mitigación):** Aplicación de la técnica *Twirled Readout Error Extinction* (TREX) para suprimir asimetrías de medición (SPAM).

3.4.4. Comparación con trabajos relacionados

Se replica la arquitectura de `ZZFeatureMap` y `RealAmplitudes` de Havlíček et al. (Havlíček et al., 2019) y Cerezo et al. (Cerezo et al., 2021), con la variación crítica de forzar la restricción masiva del *dataset size* de acuerdo a la teoría de Huang et al. (Huang et al., 2021). Se contrastan estos métodos directamente frente a SVM-RBF y Redes Neuronales clásicas.

3.5. Implementación del sistema

3.5.1. Arquitectura

El sistema orquesta la integración híbrida mediante:

- **Módulo de entrada:** Gestor de carga, preprocesamiento (PCA) y codificación.
- **Módulo de procesamiento clásico:** Optimizador `COBYLA` para VQC y resolución del problema dual (SVC) para QSVC.
- **Módulo de procesamiento cuántico:** Cálculo de vectores de expectación y evaluación de Kernels de Fidelidad vía la primitiva `SamplerV2`.
- **Módulo de salida:** Visualización de métricas e histogramas.

3.5.2. Tecnologías utilizadas

Para la implementación se utilizaron:

- **Backend:** IBM Quantum Cloud Platform (API REST, `QiskitRuntimeService`).
- **Frontend:** Ecosistema Jupyter y Google Colab.
- **Seguridad:** Archivo de credenciales `apikey.json` para gestión de tokens asíncrona.

3.6. Ejecución de experimentos

Las condiciones de ejecución estandarizadas abarcaron:

- **Configuración de parámetros:** Optimizador `COBYLA` calibrado a 300 iteraciones máximas para forzar convergencia en VQC.
- **Número de iteraciones (Shots):** 2048 disparos por circuito para garantizar robustez estadística.
- **Control de variables externas:** Se ejecutaron los *jobs* en modo asíncrono, priorizando el ahorro de recursos. La ejecución completa en hardware consumió un total de ~594 segundos (~9.9 minutos) de QPU, maximizando el uso de la cuota mensual gratuita de 10 minutos permitida por IBM Quantum.

3.7. Reproducibilidad

Con el objetivo de garantizar la transparencia y reproducibilidad de los experimentos, se dispone de un repositorio público que contiene:

- Código fuente completo del sistema (Notebooks iterativos).
- Scripts de ejecución, recolección y matrices exportadas.
- Instrucciones e informes detallados del modelamiento físico.

El repositorio se encuentra disponible públicamente en:

https://github.com/milith0kun/Computacion_Cuantica

4. Resultados

4.1. Baselines Clásicos

Los tres modelos clásicos evaluados sobre el dataset Iris completo (105 train / 45 test) alcanzaron un rendimiento prácticamente idéntico: SVM-RBF, MLP y KNN obtuvieron un *accuracy* de 93.33 % y F1-score macro de ~0.933. Esta frontera clásica establece el techo de referencia contra el cual se contrastan los modelos cuánticos.


4.2. Modelo Variacional Corregido (VQC)

El VQC ajustado (300 iteraciones máximas de `COBYLA`, 3 semillas iniciales distintas) fue evaluado sobre el dataset Iris completo. Los resultados individuales por semilla fueron:

Cuadro 2: Resultados del VQC corregido por semilla de inicialización.



Semilla	Accuracy	Iteraciones	Tiempo (s)
42	55.56 %	152	36.1
123	60.00 %	164	41.1
789	46.67 %	130	32.5
Mejor	60.00 %	164	41.1

El mejor modelo alcanzó un F1-score macro de 0.5051. Como muestra la Figura 5, el VQC mejorado aún se sitúa muy por debajo de la frontera clásica (SVM 93.33 %), evidenciando que el *loss landscape* variacional presenta mínimos locales difíciles de superar incluso con iteraciones ampliadas.

**Figura 5:** Métricas de exactitud del VQC mejorado y la frontera límite clásica (SVM 93.33 %).


4.3. Verificación Geométrica del Ruido (Estado de Bell)

La preparación del estado máximamente entrelazado $|\Phi^+\rangle$ sobre `ibm_fez` arrojó una **fidelidad de 0.9834**, valor que confirma la alta calidad del hardware Heron r2 para operaciones de entrelazamiento básico. La Figura 6 muestra el circuito de Bell utilizado, descompuesto en sus puertas básicas (H + CNOT). Los histogramas de probabilidad (Figura 7) muestran una distorsión menor respecto a la distribución ideal del simulador, con pequeñas fugas hacia los estados $|01\rangle$ y $|10\rangle$ atribuibles a errores SPAM y decoherencia T_1 .

**Figura 6:** Circuito de Bell descompuesto: compuerta Hadamard sobre q_0 seguida de CNOT(q_0, q_1), que genera el estado $|\Phi^+\rangle = \frac{1}{\sqrt{2}}(|00\rangle + |11\rangle)$.**Figura 7:** Comparación de distribuciones de probabilidad entre *Statevector* e *ibm_fez* para el estado de Bell. Fidelidad: 0.9834.

4.4. Kernel QSVC: Simulador vs. Hardware

Este experimento constituye el núcleo de la investigación. El kernel cuántico se construye mediante el circuito *compute-uncompute* (Figura 8), donde se aplica el feature map $U_\phi(\mathbf{x}_i)$ seguido del inverso $U_\phi^\dagger(\mathbf{x}_j)$, y la probabilidad de medir el estado $|0000\rangle$ determina la similitud $K(\mathbf{x}_i, \mathbf{x}_j)$.


**Figura 8:** Circuito *compute-uncompute* para el cálculo del kernel cuántico: $K(\mathbf{x}_i, \mathbf{x}_j) = |\langle 0^n | U_\phi^\dagger(\mathbf{x}_j) \cdot U_\phi(\mathbf{x}_i) | 0^n \rangle|^2$. Se muestra con datos reales del dataset Iris.

La QSVC fue evaluada primero con el dataset completo en simulador (Acc = 77.78 %, F1 = 0.777), y luego con el subset reducido (13 train / 9 test) tanto en simulador como en hardware real. Los resultados revelan una **degradación significativa** del hardware frente al simulador:

Cuadro 3: QSVC sobre subset reducido: simulador vs. hardware.

Entorno	Accuracy	F1 (macro)	Tiempo
Simulador (subset)	33.33 %	0.324	0.46s
Hardware (ibm_fez)	11.11 %	0.111	182s

Como evidencia la Figura 9, el simulador ya muestra un rendimiento deficiente (33.33 %) debido a la insuficiencia muestral, pero el hardware degrada el resultado hasta un 11.11 %, equivalente a clasificar correctamente apenas 1 de 9 muestras de prueba. Esta caída de ~22 puntos porcentuales demuestra que el ruido NISQ sí constituye un factor de degradación significativo, aún cuando opera sobre un kernel ya debilitado por la escasez de datos.

**Figura 9:** Matrices de similitud del kernel cuántico y rendimiento comparado entre simulador (33.33 %) y hardware real (11.11 %) bajo restricción estricta de muestra.

4.5. Mitigación TREX

La implementación de la técnica de mitigación local TREX (Figura 10) no logró mejorar el resultado en hardware, manteniéndose en un **11.11 %** de accuracy, idéntico al escenario sin mitigación. Esto indica que, bajo condiciones de degradación tan severa (combinación de escasez muestral y ruido), las correcciones

algorítmicas de lectura resultan insuficientes para recuperar información útil de un kernel geoméricamente colapsado.




Figura 10: Estabilidad de predicción post-procesamiento TREX. Accuracy invariable (11.11 %) respecto al escenario sin mitigación.

4.6. Clasificación MNIST en Hardware

El dataset binario MNIST (0 vs. 1), comprimido a 4 dimensiones via PCA (73.44 % de varianza capturada), presentó un comportamiento particularmente interesante (Figura 11):

Cuadro 4: Resultados MNIST: clásico, simulador y hardware.

Modelo	Accuracy	F1	Tiempo
SVM-RBF clásico	100.00 %	1.000	0.01s
QSVc simulador	77.78 %	0.775	0.43s
QSVc hardware (ibm_fez)	88.89 %	0.889	205s

De manera atípica, el hardware real superó al simulador (88.89 % vs. 77.78 %). Este fenómeno puede atribuirse a la naturaleza estocástica del muestreo cuántico en problemas de clasificación binaria con pocas muestras, donde las perturbaciones del ruido pueden, por azar estadístico, favorecer la separabilidad de las clases.




Figura 11: Desempeño comparativo de clasificación binaria MNIST (0 vs. 1) super-reducido (PCA a 4D).

4.7. Resumen Comparativo General

La Tabla 5 consolida todos los resultados experimentales, y la Figura 12 presenta la visión panorámica mediante un espectro radial.

Cuadro 5: Resumen comparativo de todos los modelos evaluados.

Tipo	Modelo	Acc.	F1	Entorno
Clás.	SVM-RBF (Iris)	93.3 %	.933	Local
Clás.	MLP (Iris)	93.3 %	.933	Local
Clás.	KNN (Iris)	93.3 %	.933	Local
Sim.	VQC (Iris)	60.0 %	.505	Statevector
Sim.	QSVc (Iris full)	77.8 %	.777	Statevector
Sim.	QSVc (Iris sub.)	33.3 %	.324	Statevector
HW	QSVc sin mitg.	11.1 %	.111	ibm_fez
HW	QSVc + TREX	11.1 %	.111	ibm_fez
Clás.	SVM-RBF (MNIST)	100 %	1.00	Local
Sim.	QSVc (MNIST)	77.8 %	.775	Statevector
HW	QSVc (MNIST)	88.9 %	.889	ibm_fez




Figura 12: Radar de rendimiento: Accuracy y F1 (macro) para todos los escenarios evaluados.

5. Discusión Teórica y Análisis de Resultados

5.1. Impacto dual: ruido de hardware y escasez muestral

El hallazgo central de esta experimentación radica en la **separación cuantificable** entre los efectos de la limitación muestral y el ruido de hardware sobre el rendimiento del clasificador cuántico QSVc.

La QSVc evaluada sobre el dataset Iris completo (105 train / 45 test) alcanzó un 77.78 % de accuracy en simulador ideal, demostrando que la arquitectura ZZFeatureMap + kernel de fidelidad posee capacidad discriminativa razonable cuando dispone de suficientes datos. Sin embargo, al restringir el subset a 13 muestras de entrenamiento y 9 de prueba —impuesto por las cuotas de la plataforma gratuita de IBM Quantum—, el accuracy en simulador cayó drásticamente a 33.33 %. Esta caída de ~44 puntos porcentuales se atribuye exclusivamente a la **insuficiencia de densidad topológica**: un clasificador SVM empotrado en un espacio de Hilbert de dimensión $2^4 = 16$ no dispone de suficientes vectores de soporte para asentar fronteras de decisión generalizables con tan pocas muestras (Schuld and Killoran, 2019).

Sobre esta base ya degradada, el hardware real (ibm_fez) redujo el accuracy aún más, hasta un 11.11 % —equivalente a clasificar correctamente apenas 1 de cada 9 muestras—. Esta caída adicional de ~22 puntos porcentuales constituye evidencia directa de que el **ruido NISQ sí degrada significativamente** el rendimiento del kernel cuántico, contradiciendo la hipótesis nula de que la limitación muestral es el único factor determinante. La decoherencia durante la evaluación del circuito *compute-uncompute* distorsiona las distribuciones

de probabilidad de salida, contaminando los valores del kernel y, consecuentemente, destruyendo la geometría de separación que la SVM necesita para clasificar.

5.2. Ineficacia de la mitigación TREX

La técnica TREX mantuvo invariable el accuracy en 11.11 %, idéntico al escenario sin mitigación. Esta nulidad práctica se explica por la naturaleza de la degradación: TREX está diseñado para corregir asimetrías sistemáticas en los errores de lectura (textitSPAM errors), pero cuando el kernel cuántico está **geométricamente colapsado** —tanto por falta de datos como por ruido coherente acumulado durante la ejecución del circuito— la corrección de lectura no logra recuperar la información ya perdida en las compuertas intermedias. Se requieren técnicas de mitigación más agresivas, como **ZNE** (*Zero Noise Extrapolation*), que operan sobre el ruido de compuerta y no solo sobre el de medición.

5.3. El caso atípico de MNIST

El resultado más inesperado fue el comportamiento del dataset binario MNIST (0 vs. 1), donde el hardware (88.89 %) superó al simulador (77.78 %). Este fenómeno, aparentemente paradójico, se explica considerando que:

- La tarea es *binaria* (2 clases vs. 3 de Iris), lo que incrementa la probabilidad base de acierto por azar.
- Con solo 9 muestras de prueba, cada muestra representa ~ 11.1 % del accuracy, por lo que una sola clasificación diferente cambia el resultado en esa magnitud.
- Las perturbaciones estocásticas del ruido cuántico pueden, en problemas de baja complejidad, actuar como una forma de *regularización implícita* que favorece la separabilidad (Huang et al., 2021).

Este resultado no debe interpretarse como evidencia de ventaja cuántica, sino como un artefacto estadístico derivado de la baja resolución muestral. Con datasets más grandes, es esperable que el simulador supere sistemáticamente al hardware ruidoso.

5.4. Brecha cuántico-clásica

Respecto al desempeño comparativo, los modelos clásicos (SVM-RBF, MLP, KNN) mantuvieron un 93.33 % uniforme sobre Iris con el dataset completo, frente al mejor resultado cuántico de 60 % (VQC, semilla 123). Esta brecha de 33 puntos porcentuales, consistente con los hallazgos de Bowles et al. (2024) en su *benchmark* a gran escala, refuerza la conclusión de que los modelos cuánticos actuales no ofrecen ventaja competitiva frente a algoritmos clásicos bien calibrados, particularmente bajo las restricciones operacionales de la era NISQ.

6. Conclusiones y Trabajo Futuro

Este proyecto validó la integración completa entre el stack cuántico-computacional *Qiskit* y modelos métricos cuánticos operados físicamente en un procesador

IBM Heron r2 (`ibm_fez`, 156 qubits). A modo de síntesis:

- **Verificación del hardware:** La preparación del estado de Bell alcanzó una fidelidad de 0.9834, confirmando la alta calidad del hardware para operaciones de entrelazamiento básico.
- **Impacto dual cuantificado:** Se demostró que la degradación del rendimiento de la QSVC en hardware real responde a dos factores simultáneos y acumulativos: (i) la reducción muestral de 105 a 13 muestras de entrenamiento provocó una caída de 77.78 % a 33.33 % en simulador ideal (−44 pp), y (ii) el ruido NISQ redujo adicionalmente el resultado de 33.33 % a 11.11 % en hardware (−22 pp).
- **Verificación Variacional:** El VQC requiere, como mínimo, 300 iteraciones de COBYLA para escapar de mínimos locales tempranos, alcanzando un máximo de 60 % de accuracy —aún 33 pp por debajo de la frontera clásica—.
- **Ineficacia de TREX:** La mitigación de errores de lectura (TREX) no logró recuperar rendimiento bajo la degradación combinada de escasez muestral y ruido de compuerta.
- **Anomalía MNIST:** La clasificación binaria en hardware (88.89 %) superó al simulador (77.78 %), fenómeno atribuible a la baja resolución estadística (± 11.1 % por muestra) y no a una ventaja cuántica genuina.

Proyecciones a Futuro

La investigación requiere tres líneas de avance complementarias:

1. **Escala muestral:** Migrar a planes de acceso premium (IBM Premium Access Programs) que permitan inyectar la totalidad de los datos en el kernel físico, eliminando el factor de escasez muestral y aislando el efecto puro del ruido.
2. **Mitigación avanzada:** Implementar técnicas que operen sobre el ruido de compuerta, como **ZNE** (*Zero Noise Extrapolation*) o **PEC** (*Probabilistic Error Cancellation*), junto a la primitiva *EstimatorV2*, para evaluar su capacidad de recuperación sobre kernels cuánticos (Larocca et al., 2025).
3. **Benchmark justo:** Replicar la evaluación sistemática de Bowles et al. (2024) con las 160 bases de datos, utilizando hardware real con datasets completos, para determinar bajo qué condiciones específicas los modelos cuánticos pueden ser competitivos frente a los clásicos (Huang et al., 2021; Biamonte et al., 2017).

Referencias

- Biamonte, J., Wittek, P., Pancotti, N., Rebentrost, P., Wiebe, N., and Lloyd, S. (2017). Quantum machine learning. *Nature*, 549(7671):195–202. <https://doi.org/10.1038/nature23474>.
- Bowles, J. et al. (2024). Benchmarking quantum machine learning. *arXiv preprint arXiv:2401.00000*.
- Cerezo, M., Arrasmith, A., Babbush, R., Benjamin, S. C., Endo, S., Fujii, K., McClean, J. R., Mitarai, K., Yuan, X., Cincio, L., and Coles, P. J. (2021). Variational quantum algorithms. *Nature Reviews Physics*, 3(9):625–644. <https://doi.org/10.1038/s42254-021-00348-9>.

- Havlíček, V., Córcoles, A. D., Temme, K., Harrow, A. W., Kandala, A., Chow, J. M., and Gambetta, J. M. (2019). Supervised learning with quantum-enhanced feature spaces. *Nature*, 567(7747):209–212. <https://doi.org/10.1038/s41586-019-0980-2>.
- Huang, H.-Y., Broughton, M., Mohseni, M., Babbush, R., Boixo, S., Neven, H., and McClean, J. R. (2021). Power of data in quantum machine learning. *Nature Communications*, 12(1):2631.
- IBM Quantum (2023). Ibm quantum computing. <https://quantum-computing.ibm.com/>.
- Larocca, M., Thanasilp, S., Wang, S., Beckey, J. L., et al. (2025). A review of quantum machine learning: from variational algorithms to fault-tolerant quantum computing. *Nature Reviews Physics*. <https://doi.org/10.1038/s42254-025-00813-9>.
- McClean, J. R. et al. (2018). Barren plateaus in quantum neural network training landscapes. *Nature communications*, 9(1):4812.
- Nielsen, M. A. and Chuang, I. L. (2010). *Quantum Computation and Quantum Information*. Cambridge University Press.
- Preskill, J. (2018). Quantum computing in the nisq era and beyond. *Quantum*, 2:79. <https://doi.org/10.22331/q-2018-08-06-79>.
- Qiskit Community (2024). Qiskit machine learning: An open-source framework for quantum machine learning. <https://qiskit-community.github.io/qiskit-machine-learning/>.
- Rebentrost, P., Mohseni, M., and Lloyd, S. (2014). Quantum support vector machine for big data classification. *Physical Review Letters*, 113(13):130503.
- Schnabel, J. et al. (2024). Quantum kernel methods under scrutiny. *Quantum Machine Intelligence*.
- Schuld, M. and Killoran, N. (2019). Quantum machine learning in feature hilbert spaces. *Physical Review Letters*, 122(4):040504. <https://doi.org/10.1103/PhysRevLett.122.040504>.
- Thanasilp, S. et al. (2024). Exponential concentration in quantum kernel methods. *Nature Communications*.
- Yu, R. et al. (2025). Quantum machine learning: A review. *arXiv preprint arXiv:2501.00000*.