



Universidad Nacional de San Antonio Abad del Cusco

DEPARTAMENTO ACADÉMICO DE INFORMÁTICA • COMPUTACIÓN CUÁNTICA

PROYECTO SEMESTRAL • MAYO 2026

Clasificación *cuántica* sobre el dataset Iris

*Comparación de los modelos VQC y QSVC frente a baselines clásicos
SVM-RBF, MLP y KNN*

AUTORES

Lozano Llacctahuaman, Medaly	195050
Puma Potosino, José Francisco	164248
Saire Bustamante, Edmil Jampier	174449

ESTRUCTURA

Contenido de la exposición

I Contexto y objetivos
Motivación y preguntas de investigación

II Marco teórico
Fundamentos cuánticos · VQC vs QSVC

III Metodología
Datasets, pipeline y configuración experimental

IV Resultados principales
Modelos clásicos · VQC · QSVC

V Experimentos sistemáticos
Feature maps · profundidad · optimizadores

VI Análisis de varianza y validación
Estabilidad y prueba en MNIST reducido

VII Discusión y limitaciones
Por qué los modelos clásicos superan

VIII Conclusiones y trabajos futuros
Lecciones y siguientes pasos

- I -

Contexto, motivación y *objetivos*

1.1 INTRODUCCIÓN

¿Por qué *quantum machine learning*?

El aprendizaje automático cuántico (QML) busca aprovechar la superposición y el entrelazamiento para resolver problemas de clasificación y optimización con un costo computacional potencialmente menor.

La promesa

- **Superposición:** un qubit codifica simultáneamente 0 y 1.
- **Entrelazamiento:** correlaciones imposibles clásicamente.
- Espacio de Hilbert de dimensión 2^n con sólo n qubits.
- Potencial ventaja en datos con estructura cuántica.

La realidad NISQ

- Hardware limitado por **ruido y decoherencia**.
- La ventaja cuántica en ML aún es un problema abierto.
- Frameworks: **Qiskit ML**, PennyLane, TFQ.
- Necesidad de evaluación empírica rigurosa.

PREGUNTA DE INVESTIGACIÓN

En un dataset clásico de baja dimensionalidad como Iris, ¿los modelos cuánticos VQC y QSVC compiten ya con SVM, MLP y KNN?

1.2 OBJETIVOS DEL PROYECTO

General y específicos

OBJETIVO GENERAL


Diseñar e implementar un modelo de aprendizaje automático basado en computación cuántica, evaluando su desempeño frente a métodos clásicos equivalentes.

Objetivos específicos

- 1 | Implementar **VQC** y **QSVC** utilizando Qiskit Machine Learning.
- 2 | Construir modelos clásicos de referencia: **SVM-RBF**, **MLP**, **KNN**.
- 3 | Comparar accuracy, precisión, recall, F1-score y tiempo de cómputo.
- 4 | Analizar influencia de **feature maps**, profundidad y optimizadores.
- 5 | Evaluar la sensibilidad al **ruido NISQ simulado**.
- 6 | Validar resultados en un segundo dataset (MNIST reducido).

- II -

Marco *teórico*



2.1 FUNDAMENTOS CUÁNTICOS

Del bit al qubit

Qubit en superposición

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle, \quad |\alpha|^2 + |\beta|^2 = 1$$

Las amplitudes complejas α, β determinan la probabilidad de medir cada estado base. Con 4 qubits manejamos un espacio de $2^4 = 16$ dimensiones.

CIRCUITO PARAMETRIZADO

Forma general	$U(x, \theta) = U_W(\theta) \cdot U_\phi(x)$
Feature map	$U_\phi(x)$ – codifica x
Ansatz	$U_W(\theta)$ – entrenable

Puertas y rotaciones

$$R_Y(\theta) = \begin{bmatrix} \cos(\theta/2) & -\sin(\theta/2) \\ \sin(\theta/2) & \cos(\theta/2) \end{bmatrix}$$

Las puertas **R_Y, R_Z** permiten codificar datos como ángulos. La **CNOT** entrelaza dos qubits, capturando correlaciones.

LIMITACIÓN PRINCIPAL

Barren plateaus: ansatz demasiado profundos producen gradientes que se desvanecen exponencialmente, impidiendo el entrenamiento.

2.2 DOS ENFOQUES CUÁNTICOS

VQC y QSVC: filosofías opuestas

VQC – VARIATIONAL QUANTUM CLASSIFIER

Entrenamiento híbrido cuántico-clásico

- Circuito parametrizado $U(x, \theta)$.
- Optimizador **clásico** ajusta θ paso a paso.
- Función de pérdida: **entropía cruzada**.
- Análogo cuántico de una red neuronal.

$$L(\theta) = -(1/N) \sum y_{ic} \log \hat{y}_{ic}(\theta)$$

QSVC – QUANTUM SUPPORT VECTOR CLASSIFIER

Sin optimización variacional

- Kernel **cuántico** basado en fidelidad de estados.
- SVM clásico decide los vectores soporte.
- Sólo se calcula el kernel, no se entrena un circuito.
- Más estable, menos sensible a inicialización.


$$K_Q(x_i, x_j) = |\langle \phi(x_j) | \phi(x_i) \rangle|^2$$

IMPLICACIÓN PRÁCTICA

El VQC depende de un optimizador clásico que puede atascarse. El QSVC delega la decisión a un SVM probado. **Veremos que esta distinción cambia drásticamente los resultados.**

- III -

Metodología experimental



3.1 DATASETS UTILIZADOS

Dos benchmarks clásicos

DATASET PRINCIPAL

Iris

- **150 muestras** distribuidas en 3 clases (50 c/u).
- 4 features: longitud y ancho de sépalo y pétalo.
- Setosa: linealmente separable.
- Versicolor / Virginica: solapamiento parcial.

VALIDACIÓN EXTERNA

MNIST reducido

- Dígitos **0 vs 1**, 360 muestras totales.
- **PCA** aplicado: $64 \rightarrow 4$ componentes.
- Tarea binaria, más sencilla que Iris.
- Comprueba si las conclusiones generalizan.

PREPROCESAMIENTO COMÚN

MinMaxScaler al rango $[0, \pi]$ para codificación angular. One-hot encoding para VQC. Split estratificado 70 / 30 con semilla fija **42**.

3.2 PIPELINE EXPERIMENTAL


Procedimiento en cuatro etapas



3.3 DISEÑO DEL CIRCUITO CUÁNTICO

Lo que se ejecuta sobre los qubits

FIGURA 1




Arriba: ZZFeatureMap (reps=2). Centro: RealAmplitudes (reps=3). Abajo: circuito completo.

LECTURA > El **feature map ZZFeatureMap** codifica las cuatro features de Iris en cuatro qubits mediante rotaciones R_Z y compuertas R_{ZZ} , generando correlaciones de segundo orden. El **ansatz RealAmplitudes** incorpora 16 parámetros θ entrenables organizados en tres capas de R_y + CNOT. La inteligencia del modelo reside enteramente en esos 16 ángulos.

- IV -


Resultados principales



4.1 ANÁLISIS EXPLORATORIO DEL DATASET

¿Iris es fácil o difícil?

FIGURA 2

*Distribución de las muestras de Iris por pares de características.*

LECTURA > Cada subplot enfrenta dos features de Iris. **Setosa (azul)** aparece *aislada* en todos los pares: cualquier modelo lineal la clasifica. **Versicolor y Virginica** se solapan en sépalo y sólo se separan claramente con *petal length* × *petal width*. Conclusión: Iris es trivial para clásicos en dos de las tres clases; el verdadero reto es distinguir las clases que se mezclan.

4.2 RESULTADOS DE MODELOS CLÁSICOS

Los baselines empatan en 93.33%

MODELO	ACCURACY	PRECISION	F1	TIEMPO (S)
SVM-RBF	0.933	0.935	0.933	0.001
MLP (16, 8)	0.933	0.935	0.933	0.108
KNN (k=5)	0.933	0.944	0.933	<0.001


VALIDACIÓN CRUZADA 5-FOLD

El SVM-RBF en 5-fold CV se mantiene en **0.960 ± 0.039**, confirmando que los baselines clásicos resuelven Iris en milisegundos con alta estabilidad. La pregunta es entonces: **¿pueden VQC y QSVC al menos aproximarse?**

4.3 VQC: CONVERGENCIA DE LA PÉRDIDA

El VQC se atasca en una meseta

FIGURA 3




Evolución de la entropía cruzada durante el entrenamiento del VQC con COBYLA (200 iter).

LECTURA > COBYLA reduce la entropía cruzada de 11.86 a 11.66 en las primeras 30 iteraciones, y a partir de allí *oscila sin avanzar*. La mejora total es marginal (≈ 0.2 unidades). Este es el diagnóstico clínico del problema: el VQC inicia el aprendizaje pero el paisaje de optimización es plano. **Resultado: accuracy de 37.78%** — apenas mejor que el azar (33%) en una tarea de tres clases.

4.4 MATRICES DE CONFUSIÓN

¿Dónde se equivoca cada modelo?

FIGURA 4




Matrices de confusión para los cinco modelos evaluados sobre el conjunto de test de Iris.

LECTURA > **Clásicos:** la diagonal es casi perfecta, con sólo 2-3 confusiones entre versicolor↔virginica (el solapamiento observado en el EDA). **VQC:** caótico — la columna de virginica queda *vacía*, el modelo nunca la predice. **QSVC:** razonable, distingue las tres clases con errores moderados. El VQC colapsó sus predicciones en dos clases.

4.5 COMPARACIÓN GENERAL CLÁSICOS VS CUÁNTICOS

Accuracy frente a tiempo de entrenamiento

FIGURA 5




Izquierda: accuracy por modelo. Derecha: tiempo de entrenamiento en escala logarítmica.

LECTURA > Azul = clásicos; morado = cuánticos. A la izquierda los tres clásicos comparten 93.3%, mientras VQC y QSVC se ubican muy por debajo. A la derecha la escala logarítmica revela el verdadero costo: el VQC tarda $\approx 30\,000\times$ más que un SVM. Resumen del proyecto: mucho más cómputo cuántico, mucho menos rendimiento.

4.6 FRONTERA DE DECISIÓN DEL SVM

El espacio de decisión en 2D


FIGURA 6

*Frontera de decisión del SVM-RBF en proyección PCA 2D.*

LECTURA > Proyectamos Iris a dos dimensiones con PCA (PC1 captura el **83.6%** de la varianza). El SVM con kernel RBF construye fronteras *curvas* que aíslan setosa (azul) a la izquierda y virginica (verde) a la derecha. La **zona central** es donde versicolor y virginica se confunden — corresponde exactamente a los 2-3 errores observados en la matriz de confusión. Geometría sencilla, problema sencillo para clásicos.

— V —


Experimentos *sistemáticos*



5.1 COMPARACIÓN DE FEATURE MAPS

La paradoja del feature map

FIGURA 7




Accuracy por feature map y curvas de convergencia de la pérdida.

LECTURA > Cuatro feature maps con el mismo ansatz. El ganador sorpresivo es **ZFeatureMap (66.7%)** — el más simple, *sin entrelazamiento*. ZZFeatureMap (linear) y PauliFeatureMap, mucho más expresivos, obtienen peor accuracy. La curva derecha lo confirma: ZFeatureMap converge a una pérdida menor. Lección clave: con 150 iteraciones, un circuito simple se entrena mejor que uno expresivo con paisaje plano. **Más complejidad ≠ mejor rendimiento.**

5.2 PROFUNDIDAD DEL ANSATZ

Tendencia monótona del accuracy

FIGURA 8


*Accuracy vs repeticiones del ansatz y convergencia por profundidad.*

LECTURA > Variando $\text{reps} \in \{1, 2, 3, 5\}$, el accuracy **sube monótonamente** de 31% a 53%. Con $\text{reps}=5$ tenemos 24 parámetros y el VQC alcanza su mejor desempeño. A la derecha, $\text{reps}=5$ (rojo) converge a una pérdida menor. Buena noticia: no observamos *barren plateau* en este rango. Mala noticia: incluso así, el modelo se mantiene lejos del 93% clásico.

5.3 COMPARACIÓN DE OPTIMIZADORES

¿Qué optimizador entrena mejor al VQC?

FIGURA 9




Accuracy por optimizador y curvas de convergencia.

LECTURA > Tres optimizadores compiten. **COBYLA** gana con 62.2% en sólo 44 s — método libre de gradiente, ideal para simulación statevector. **SPSA** (55.6%, 149 s) está diseñado para hardware *ruidoso*; gasta de más cuando no hay ruido que enfrentar. **L-BFGS-B** (57.8%, 204 s) converge en 17 iteraciones pero cada paso es costoso por el cálculo de gradientes. Recomendación: COBYLA en simulación; SPSA cuando se pase a hardware real.

5.4 KERNEL CUÁNTICO VS KERNEL RBF

Cómo «ven» los datos los dos kernels

FIGURA 10




Izquierda: kernel cuántico (ZZFeatureMap). Derecha: kernel RBF clásico.

LECTURA > Cada celda mide la **similitud** entre dos muestras. **Izquierda · cuántico:** matriz dispersa con diagonal brillante y pocas similitudes off-diagonal. **Derecha · RBF:** bloques amarillos compactos donde las muestras de una misma clase se reconocen fuertemente entre sí. Esa estructura de bloques es lo que le da al SVM-RBF su 93%. El kernel cuántico, aunque elegante, no agrupa la información tan claramente para este dataset.

6.1 VARIANZA DEL VQC

El VQC es inestable entre semillas

FIGURA 11




Distribución de accuracy: VQC (5 semillas) vs SVM-RBF (5-fold CV).

LECTURA > El VQC ejecutado con **5 semillas aleatorias** distintas oscila entre 38% y 60% (mediana 47%, $\sigma = 0.076$). El SVM-RBF en CV 5-fold se mantiene *siempre* entre 90% y 100% ($\sigma = 0.039$). El VQC es impredecible: la inicialización aleatoria de θ cambia drásticamente el resultado. Para uso real, esto es un problema serio.

6.2 VALIDACIÓN CRUZADA EN MNIST REDUCIDO

Misma historia en MNIST 0 vs 1

FIGURA 12




Izquierda: accuracy SVM vs VQC en MNIST reducido. Derecha: convergencia del VQC.

LECTURA > Repetimos el experimento en MNIST reducido (0 vs 1, tarea *binaria*). **SVM-RBF: 100%** — clasifica perfectamente. **VQC: 69.4%** — mejor que en Iris (porque sólo hay dos clases), pero aún muy por debajo. A la derecha, la pérdida del VQC sí decrece claramente de 1.15 a 0.85, lo que muestra que *sí está aprendiendo*... aunque insuficientemente. **La conclusión generaliza más allá de Iris.**

- VII -

Discusión y *limitaciones*



7.1 SÍNTESIS CRÍTICA

¿Por qué los clásicos superan?

RAZÓN 1

Datos sin estructura cuántica

Huang et al. (2021): la ventaja cuántica requiere datos cuya geometría no se capture con kernels clásicos. Iris vive en $\mathbb{R}^4$ y es casi linealmente separable.

RAZÓN 2

VQC mal entrenado

200 iteraciones de COBYLA son insuficientes para tres clases. El paisaje de pérdida es plano y la inicialización aleatoria condiciona la convergencia.

RAZÓN 3

QSVC supera al VQC

Sin entrenamiento variacional, el QSVC delega la decisión al SVM. Es más estable y por eso alcanza 77.8% — aunque sigue pagando el costo del cómputo cuántico.

LIMITACIONES DECLARADAS

Simulación statevector (sin ruido NISQ real) · Iris y MNIST son datasets pequeños · No se exploraron ansatz adaptativos ni mitigación de errores · 150-200 iteraciones pueden quedar cortas.

8.1 CONCLUSIONES DEL PROYECTO

Siete hallazgos principales

- 1 | Se implementaron exitosamente **VQC** y **QSVC** con Qiskit ML 0.9.0, demostrando la viabilidad técnica del enfoque híbrido cuántico-clásico.
- 2 | Los modelos clásicos obtuvieron **93.33%** de accuracy, superando a QSVC (77.78%) y a VQC (37.78%) en Iris — consistente con la literatura.
- 3 | El **QSVC supera al VQC**: los métodos basados en kernel cuántico son más estables que los variacionales para este tipo de problema.
- 4 | Mayor expresividad del feature map **no implica** mejor rendimiento cuando el optimizador tiene iteraciones limitadas.
- 5 | La **profundidad del ansatz** muestra relación monótona con el accuracy (reps 1→5), sin evidencia de *barren plateau*.
- 6 | **COBYLA** resulta el optimizador más eficiente para simulación statevector; SPSA sería preferible en hardware real.
- 7 | El VQC presenta **alta varianza entre semillas** ($\sigma = 0.076$), lo que limita su confiabilidad para uso práctico.

8.2 LÍNEAS DE CONTINUACIÓN

Hacia dónde llevar este trabajo

Corto plazo

- Evaluar en **hardware IBM Quantum** real para medir el impacto del ruido de decoherencia.
- **Mitigación de errores:** Zero-Noise Extrapolation y readout calibration.
- Aumentar las iteraciones del optimizador (500-1000) para verificar convergencia plena.

Largo plazo

- Explorar **ansatz adaptativos** (ADAPT-VQE) que ajusten su arquitectura.
- Aplicar a datasets de mayor dimensionalidad o con **estructura cuántica intrínseca** (química molecular).
- Investigar **kernels cuánticos covariantes** que aprovechen simetrías del problema.

HIPÓTESIS A COMPROBAR

*Iris fue un campo de pruebas. La **verdadera ventaja cuántica** aparecerá cuando los datos vivan naturalmente en el espacio de Hilbert. El próximo dataset debe elegirse con esa pregunta en mente.*



FIN DE LA EXPOSICIÓN

Gracias por su *atención*

*Preguntas, comentarios y discusión sobre los resultados,
la metodología o los siguientes pasos del proyecto.*

SVM-RBF · 93.3%

QSVC · 77.8%

VQC · 37.8%

AUTORES

Lozano Llacctahuaman, Medaly
195050

Puma Potosino, José Francisco
164248

Saire Bustamante, Edmil Jampier
174449